

# Введение, Марковский процесс принятия решений

Алексей Скрынник

# ПЛАН

---

- 01 Введение
- 02 Многорукие бандиты
- 03 Цепи Маркова
- 04 Марковский процесс с вознаграждениями
- 05 Марковский процесс принятия решений

# 01



## Введение

# Идея обучения с подкреплением

Программа учится выбирать действия по их последствиям.


- Выполняет действие и наблюдает результат.
- Получает вознаграждение — численную оценку результата.
- Использует накопленный опыт для следующих решений.
- Учится получать больше вознаграждения за последовательность действий.



## Долгосрочное влияние

Ход может казаться невыгодным сейчас, но приближать победу. Обучение помогает понять, какие решения ведут к успеху.

# Обучение с подкреплением и другие науки



# Психология животных

- **Положительное подкрепление:** добавить приятный стимул, например дать корм после нажатия на рычаг.
- **Отрицательное подкрепление:** убрать неприятный стимул, например выключить громкий звук при нажатии на рычаг.
- Оба вида подкрепления помогают закрепить поведение и используются для обучения животных.
- Боль и голод могут побуждать к действию, но сами по себе не являются отрицательным подкреплением.




# Где применяется обучение с подкреплением?

- Игры: го, нарды, видеоигры
- Исследование операций: цены, маршруты доставки
- Управление лифтами
- Управление роботами
- Беспилотный транспорт
- Голосовые и диалоговые системы
- Рассуждения и использование инструментов в LLM
- Энергоэффективность дата-центров
- Автоматическое управление сетями
- Финансы: торговля и исполнение заявок

# Исследование операций: маршруты доставки



- **Агент:** система доставки.
- **Среда:** дороги и заказы.
- **Состояние:** машины, загрузка, сроки заказов.
- **Действие:** выбрать следующего клиента.
- **Вознаграждение:** минус затраты на доставку.





# Управление роботами

- **Агент:** контроллер робота.
- **Среда:** предметы и рабочая зона.
- **Состояние:** положение робота и предметов.
- **Действие:** двигать суставами и захватом.
- **Вознаграждение:** за успешную установку предмета.



# Настольные игры

- **Агент:** шахматная программа.
- **Среда:** доска и соперник.
- **Состояние:** позиция и очередь хода.
- **Действие:** сделать ход.
- **Вознаграждение:** +1 / 0 / -1: победа / ничья / поражение.




# Видеоигры

- **Агент:** игрок в Capture the Flag.
- **Среда:** арена, союзники и соперники.
- **Наблюдение:** вид от первого лица, счёт, здоровье.
- **Действие:** двигаться, поворачивать, стрелять.
- **Вознаграждение:** за победу команды.




# Обучение с подкреплением для LLM

- **Агент:** языковая модель.
- **Среда:** задачи и проверка решений.
- **Состояние:** запрос и уже написанный текст.
- **Действие:** выбрать следующий токен.
- **Вознаграждение:** правильность и формат ответа.



# Финансы: алгоритмическая торговля

- **Агент:** торговый алгоритм.
- **Среда:** рынок.
- **Наблюдение:** цены, заявки, текущий портфель.
- **Действие:** купить, продать или ждать.
- **Вознаграждение:** прибыль с учётом издержек и риска.



# В чем сложности обучения с подкреплением?

Обучение с подкреплением объединяет обучение и принятие решений.

- **Стохастическая среда:** одно действие может приводить к разным результатам.
- **Неполная модель:** агенту может быть неизвестна реакция среды.
- **Взаимосвязанные решения:** выбор меняет будущие возможности.
- **Нет учителя:** не требуется указывать правильное действие на каждом шаге.
- **Частичная и отложенная обратная связь:** виден результат выбранного действия, но его значимость может проявиться гораздо позже.

Вознаграждение оценивает результат, но не объясняет, как его добиться.



# Где ловить рыбу?

- На выбор три места. У вас **20 забросов**.
- За один заброс можно поймать одну рыбу или остаться без улова.
- Вероятность поймать рыбу зависит от места и заранее неизвестна.
- Цель — поймать как можно больше рыбы.



**После двух забросов в точке A вы ничего не поймали. Остаться или сменить место?**

# 02



## Многорукые бандиты



# Многорукие бандиты

## Определение

В задаче **стохастического многорукого бандита** агент на каждом шаге выбирает действие  $a_t \in \mathcal{A}$  и наблюдает только его вознаграждение  $r_t$ .


- Каждому действию соответствует неизвестное фиксированное распределение вознаграждений; выборки из него независимы.
- $Q(a) = \mathbb{E}[r_t \mid a_t = a]$  — среднее вознаграждение действия.
- Цель — максимизировать  $\mathbb{E} \left[ \sum_{t=1}^T r_t \right]$ .

**На рыбалке:**  $\mathcal{A} = \{A, B, C\}$  — места;  $r_t = 1$  за рыбу и 0 без улова.  $Q(a)$  — вероятность поймать рыбу в месте  $a$ .

# Пример: выбор игрового автомата

Та же задача: каждый автомат — отдельное действие.

- На каждом шаге выбираем **один автомат**.
- Получаем случайное **вознаграждение** — выплату автомата.
- Средняя выплата  $Q(a)$  каждого автомата неизвестна.
- Цель — максимальная **суммарная выплата** за заданное число попыток.



Ещё один пример — реклама: вместо выплат будем считать клики по объявлениям.

# Наш пример: три рекламных объявления

Для каждого посетителя сайт выбирает одно из трёх объявлений.

- **Агент:** система выбора рекламы.
- **Среда:** поток посетителей из аудитории с неизменными характеристиками.
- **Действие:** показать объявление  $A$ ,  $B$  или  $C$ .
- **Вознаграждение:** 1 за клик; 0, если клика нет.
- **Неизвестны:** вероятности клика  $Q(A)$ ,  $Q(B)$ ,  $Q(C)$ .

## Упрощения модели

Реакции посетителей независимы. Вероятность клика для каждого объявления постоянна. Текущий выбор не меняет будущую аудиторию и доступные объявления.

Цель — максимизировать ожидаемое суммарное число кликов.

# Исследование и использование

Пусть у объявления  $A$  пока самая высокая наблюдаемая доля кликов.

- **Использование:** показываем  $A$ , опираясь на накопленный опыт.
- **Исследование:** пробуем  $B$  или  $C$ , чтобы лучше оценить их вероятности клика.
- Видим результат только показанного объявления. Не знаем, кликнул бы этот посетитель на другое.

## Одного наблюдения недостаточно

Один раз показали  $C$  и получили 0. Истинная вероятность клика всё ещё может быть высокой: даже на хорошее объявление кликают не всегда.

Исследование даёт информацию для будущих решений, но сейчас может уменьшить ожидаемое число кликов.

# Учимся по вознаграждениям: жадная стратегия

После 7 показов накопились такие наблюдения:

| Действие | Вознаграждения | Число показов | Оценка $\hat{Q}(a)$ |
|----------|----------------|---------------|---------------------|
| $A$      | 1, 1, 0, 1     | 4             | $3/4 = 0.75$        |
| $B$      | 1, 0           | 2             | $1/2 = 0.50$        |
| $C$      | 0              | 1             | $0/1 = 0.00$        |

- $\hat{Q}(a)$  оценивает неизвестное  $Q(a)$  как среднее наблюдаемых вознаграждений.
- **Стратегия** — правило выбора действий. Жадная стратегия выбирает наибольшую оценку: объявление  $A$ .

**Следующий показ: выбираем  $A$  и получаем 0**

Обновляем только  $A$ : новая оценка  $(1 + 1 + 0 + 1 + 0)/5 = 0.60$ . Оценки  $B$  и  $C$  не меняются: 0.50 и 0.00.

Может ли  $C$  оказаться лучшим? Из-за одной неудачи жадная стратегия может больше его не пробовать.

## $\epsilon$ -жадная стратегия: иногда исследуем

Текущие оценки:  $A : 0.60$ ,  $B : 0.50$ ,  $C : 0.00$ .

- С вероятностью  $1 - \epsilon$  выбираем наибольшую оценку:  $A$ .
- С вероятностью  $\epsilon$  равномерно выбираем одно из трёх действий.

**Пример:  $\epsilon = 0.3$**

В 70% случаев выбираем жадно, в 30% — случайно. Случайный выбор даёт каждому объявлению ещё 10%, в том числе  $A$ .


| Объявление $A$       | Объявление $B$ | Объявление $C$ |
|----------------------|----------------|----------------|
| $70\% + 10\% = 80\%$ | 10%            | 10%            |

Так мы продолжаем собирать данные об альтернативных действиях.

# От бандитов к обучению с подкреплением

Три идеи для дальнейшего изучения:

- **Агент** выбирает действия с помощью **стратегии**.
- Учится по **вознаграждениям**, стремясь увеличить их сумму.
- Сочетает **исследование** и **использование**.



## Дальше: действия меняют ситуацию

Выбор автомата не меняет остальные варианты. Движение робота расходует заряд и меняет его будущие возможности. Для описания ситуации нужно **состояние**.

# 03




## Цепи Маркова



# Достаточно ли последнего сигнала?

## Как представить состояние агента $s_t^a$ ?


- Последние три события в последовательности.
- Количество появлений света, звонка и рычага.
- Вся последовательность.



## Что нужно помнить, чтобы предсказать результат?

# Лягушка и три листа кувшинки

- Состояние  $s_t$  — текущий лист.
- Начинаем на  $A$ , заканчиваем на  $G$ .
- Правила прыжков фиксированы: мы только наблюдаем.




**Сколько прыжков осталось до  $G$ ?**

# Почему достаточно текущего листа?

На  $B$  следующий прыжок ведёт на  $A$  или  $G$  с вероятностью  $1/2$ .

Неважно, сколько раз лягушка уже возвращалась на  $B$ .

**Марковское свойство:** при известном состоянии история не меняет распределение следующего состояния.



# Марковский процесс

## Определение

**Марковский процесс** с конечным множеством состояний — цепь Маркова, задаваемая парой  $\langle S, \mathcal{P} \rangle$ :

- ▶  $S$  — множество состояний;
- ▶  $\mathcal{P}_{ss'} = \mathbb{P}(s_{t+1} = s' \mid s_t = s)$  — вероятность перехода.

При известном текущем состоянии история не меняет распределение следующего:

$$\mathbb{P}(s_{t+1} \mid s_t, \dots, s_0) = \mathbb{P}(s_{t+1} \mid s_t).$$


**Для лягушки:**  $S = \{A, B, G\}$ ; вероятности переходов заданы стрелками.

# От рисунка к матрице переходов

$$\mathcal{P}_{ss'} = \mathbb{P}(s_{t+1} = s' \mid s_t = s).$$

$$\mathcal{P} = \begin{array}{c|ccc} & A & B & G \\ \hline A & 0 & 1 & 0 \\ B & 1/2 & 0 & 1/2 \\ G & 0 & 0 & 1 \end{array}$$

Строка — откуда, столбец — куда. Сумма строки равна 1.



# Одни правила — разные траектории

## Два прыжка

$$A \xrightarrow{1} B \xrightarrow{1/2} G$$

$$\mathbb{P}(\text{этот путь}) = 1 \cdot \frac{1}{2} = \frac{1}{2}.$$

## Четыре прыжка

$$A \xrightarrow{1} B \xrightarrow{1/2} A \xrightarrow{1} B \xrightarrow{1/2} G$$

$$\mathbb{P}(\text{этот путь}) = 1 \cdot \frac{1}{2} \cdot 1 \cdot \frac{1}{2} = \frac{1}{4}.$$

Над стрелками — вероятности. Для одного пути перемножаем их.

Возвратов на  $A$  может быть больше: число прыжков случайно.

# 04

---

## Марковский процесс с вознаграждениями

# Марковский процесс с вознаграждениями

## Определение

**Марковский процесс с вознаграждениями** — кортеж  $\langle S, \mathcal{P}, \mathcal{R}, \gamma \rangle$ , где

- ▶  $S$  и  $\mathcal{P}$  — состояния и переходы цепи Маркова;
- ▶  $\mathcal{R}(s) = \mathbb{E}[r_{t+1} \mid s_t = s]$  — ожидаемое вознаграждение за переход из  $s$ ;
- ▶  $\gamma \in [0, 1]$  — коэффициент дисконтирования.

**Для лягушки:** сохраняем переходы и назначаем  $-1$  за каждый прыжок:

$$\mathcal{R}(A) = \mathcal{R}(B) = -1, \quad \mathcal{R}(G) = 0.$$

Сначала используем  $\gamma = 1$ : все вознаграждения имеют одинаковый вес.



# Каждый прыжок даёт $-1$

Те же переходы. Добавим вознаграждение  $r_{t+1} = -1$  за каждый прыжок, включая последний.

$$A \xrightarrow{-1} B \xrightarrow{-1} G$$

$$G_0 = -1 - 1 = -2.$$

$$A \xrightarrow{-1} B \xrightarrow{-1} A \xrightarrow{-1} B \xrightarrow{-1} G$$

$$G_0 = -1 - 1 - 1 - 1 = -4.$$

**Вознаграждение** — за один переход. **Отдача**  $G_t$  — сумма будущих вознаграждений до конца эпизода.

# Сколько прыжков осталось в среднем?


Отдача одного эпизода случайна:  $-2, -4, -6, \dots$

**Полезность состояния** — ожидаемая отдача при старте из него:

$$V(s) = \mathbb{E}[G_t \mid s_t = s].$$

Для лягушки  $V(s)$  — минус  
ожидаемое число прыжков до  $G$ .

$V(G) = 0$ : путь уже закончен.




## Один прыжок сейчас, затем оставшийся путь

Из  $B$  сначала получаем  $-1$ .

Затем с вероятностью  $1/2$ :

- возвращаемся на  $A$ : остаётся  $V(A)$ ;
- достигаем  $G$ : остаётся  $0$ .



$$V(B) = \underbrace{-1}_{\text{сейчас}} + \underbrace{\frac{1}{2}V(A) + \frac{1}{2} \cdot 0}_{\text{ожидаемая отдача после прыжка}}.$$

# Уравнение Беллмана

## Определение

**Уравнение Беллмана** связывает полезность текущего состояния с наградой за ближайший переход и полезностями следующих состояний. При  $\gamma = 1$ :

$$V(s) = \underbrace{\mathcal{R}(s)}_{\text{ожидаемая награда сейчас}} + \underbrace{\sum_{s' \in S} \mathcal{P}_{ss'} V(s')}_{\text{ожидаемая полезность после перехода}}.$$

В основе тот же шаг, что и в примере с лягушкой:

$$G_t = r_{t+1} + G_{t+1}.$$

**Зачем это нужно?** Вместо перебора всех траекторий составляем систему уравнений для  $V(s)$ .


# Уравнение Беллмана: найдём полезности

$$V(A) = -1 + V(B),$$

$$V(B) = -1 + \frac{1}{2}V(A),$$

$$V(G) = 0.$$

|                               |
|-------------------------------|
| $V(A) = -4, \quad V(B) = -3.$ |
|-------------------------------|



Из  $A$  остаётся в среднем четыре прыжка, из  $B$  — три.

# Дисконтирование: меньший вес далёкого будущего

Теперь введём коэффициент  $\gamma \in [0, 1]$ :

$$G_t = r_{t+1} + \gamma r_{t+2} + \gamma^2 r_{t+3} + \dots$$

Для четырёх прыжков при  $\gamma = 0.9$ :

$$G_0 = -1 - 0.9 - 0.81 - 0.729 = -3.439.$$

В уравнении Беллмана будущая полезность тоже получает вес  $\gamma$ :

$$V(s) = \mathcal{R}(s) + \gamma \sum_{s'} \mathcal{P}_{ss'} V(s').$$

**При  $\gamma = 1$  возвращаемся к предыдущему расчёту.**

# От предсказания к управлению

- **Цепь Маркова:** предсказываем, куда попадёт лягушка.
- **Процесс с вознаграждениями:** предсказываем отдачу из каждого состояния.

До сих пор правила прыжков были фиксированы.

**Что изменится, если агент сможет выбирать действие?**

От выбора будут зависеть переходы и вознаграждения. Получим **марковский процесс принятия решений (МППР)**.

# 05

---

## Марковский процесс принятия решений



# Марковский процесс принятия решений

## Определение

Марковский процесс принятия решений (МППР) – это кортеж  $\langle S, A, \mathcal{P}, \mathcal{R}, \gamma \rangle$ , где

- $S$  – конечное множество состояний,
- $A$  – конечное множество действий,
- $\mathcal{P}$  – матрица вероятностей переходов:

$$\mathcal{P}_{ss'}^a = \mathbb{P}[s_{t+1} = s' | s_t = s, a_t = a],$$

- $\mathcal{R}$  – функция вознаграждения  $\mathcal{R}_s^a = \mathbb{E}[r_{t+1} | s_t = s, a_t = a]$ ,
- $\gamma \in [0, 1]$  – дисконтирующий множитель.

# Стратегии

## Определение


Стратегией  $\pi$  будем называть вероятностное распределение на множестве действий при текущем состоянии  $s$ :

$$\pi(a|s) = \mathbb{P}[a_t = a | s_t = s]$$

- Стратегия полностью определяет поведение агента.
- МППР стратегии зависят от текущего состояния.
- Стратегии стационарны (не зависят от времени):

$$a_t \sim \pi(\cdot | s_t), \forall t \geq 0.$$


# Пример 1: Алиса в Стране чудес



## Пример 2: Лабиринт

**Цель:** добраться до сыра за меньшее число шагов.


- **Состояние:** текущая клетка.
- **Действия:**  $\uparrow, \downarrow, \leftarrow, \rightarrow$ .
- **Вознаграждение:**  $-1$  за попытку шага.
- У стены мышь остаётся на месте.
- На клетке с сыром эпизод заканчивается.



# Лабиринт: стратегия

**Стратегия  $\pi$ :** какое действие выбрать в каждой клетке.

- Стрелка показывает выбранное действие.
- Стратегия задаёт поведение на всей карте.




## Лабиринт: полезность состояния

**Полезность  $V^\pi(s)$ :** сколько суммарного вознаграждения осталось получить.

- Следуем показанной стратегии;  
 $\gamma = 1$ .
- Каждый шаг даёт  $-1$ .
- Из  $A$  до сыра три шага:  

$$V^\pi(A) = -3, \quad V^\pi(G) = 0.$$



# Лабиринт: дисконтирование


Из  $S$  к сыру можно пройти двумя маршрутами. Каждый шаг по-прежнему даёт  $-1$ .

$$G_n = - \sum_{k=0}^{n-1} \gamma^k$$

11 шагов 15 шагов

|                |                   |                   |
|----------------|-------------------|-------------------|
| $\gamma = 1$   | $-11$             | $-15$             |
| $\gamma = 0.9$ | $\approx -6.86$   | $\approx -7.94$   |
| $\gamma = 0.5$ | $\approx -1.9990$ | $\approx -1.9999$ |

При малом  $\gamma$  отдачи почти одинаковы: далёкие штрафы имеют малый вес.



Вопросы?