

Динамическое программирование

Алексей Скрынник

ПЛАН

- 01 МПР и уравнение Беллмана
- 02 Алгоритм итерации по стратегиям
- 03 Алгоритм итерации по полезностям

01

МППР и уравнение Беллмана

Марковский процесс принятия решений

Марковский процесс принятия решений – это марковский процесс вознаграждения для действий. Он описывает взаимодействие со средой с марковскими состояниями.

Определение


Марковский процесс принятия решений (МППР) – это кортеж $\langle S, A, \mathcal{P}, \mathcal{R}, \gamma \rangle$, где

- S – конечное множество состояний,
- A – конечное множество действий,
- $\mathcal{P}$ – матрица вероятностей переходов:

$$\mathcal{P}_{ss'}^a = \mathbb{P}[s_{t+1} = s' | s_t = s, a_t = a],$$

- $\mathcal{R}$ – функция вознаграждения $\mathcal{R}_s^a = \mathbb{E}[r_{t+1} | s_t = s, a_t = a]$,
- $\gamma \in [0, 1]$ – дисконтирующий множитель.

Пример: Алиса в Стране чудес



Стратегии

Определение

Стратегией π будем называть вероятностное распределение на множестве действий при текущем состоянии s :

$$\pi(a|s) = \mathbb{P}[a_t = a | s_t = s]$$

- Стратегия полностью определяет поведение агента.
- МППР стратегии зависят от текущего состояния.
- Стратегии стационарны (не зависят от времени):

$$a_t \sim \pi(\cdot | s_t), \forall t \geq 0.$$

Стратегии

- Пусть дан МППР $\mathcal{M} = \langle S, A, \mathcal{P}, \mathcal{R}, \gamma \rangle$ и стратегия π
- Последовательность состояний и вознаграждений $s_0, r_0, s_1, \dots$ – марковского процесса принятия решений $\langle S, \mathcal{P}^\pi, \mathcal{R}^\pi, \gamma \rangle$, где

$$\mathcal{P}_{ss'}^\pi = \sum_{a \in A} \pi(a|s) \mathcal{P}_{ss'}^a$$

$$\mathcal{R}_s^\pi = \sum_{a \in A} \pi(a|s) \mathcal{R}_s^a$$

Функция Полезности

Функция полезности

Определение

Функцией полезности состояний МППР $V^\pi(s)$ будем называть математическое ожидание отдачи, полученной, начиная с состояния s , при выполнении стратегии π :


$$V^\pi(s) = \mathbb{E}_\pi[G_t | s_t = s]$$

Определение

Функцией полезности действий МППР $Q^\pi(s, a)$ будем называть математическое ожидание отдачи, полученной, начиная с состояния s и выбранного действия a , при выполнении стратегии π :

$$Q^\pi(s, a) = \mathbb{E}_\pi[G_t | s_t = s, a_t = a]$$

Алиса: полезность случайной стратегии



Уравнение Беллмана для МППР

Функция полезности состояний может быть разложена на немедленное вознаграждение и дисконтированную полезность следующего состояния:

$$V^{\pi}(s) = \mathbb{E}_{\pi}[r_{t+1} + \gamma V^{\pi}(s_{t+1}) | s_t = s]$$


Для функции полезности действий аналогично:

$$Q^{\pi}(s, a) = \mathbb{E}_{\pi}[r_{t+1} + \gamma Q^{\pi}(s_{t+1}, a_{t+1}) | s_t = s, a_t = a]$$

Уравнение Беллмана для V^π

Из полезности действий — в полезность состояния.

- В состоянии s стратегия выбирает действие a с вероятностью $\pi(a|s)$.
- Каждому действию соответствует своя ожидаемая отдача $Q^\pi(s, a)$.
- Усредняем эти значения по стратегии и получаем $V^\pi(s)$.




Белый узел — состояние; чёрный — действие.

$$V^\pi(s) = \sum_{a \in A} \pi(a|s) Q^\pi(s, a)$$

Уравнение Беллмана для Q^π

Первое действие уже выбрано.

- Выполняем a в состоянии s и получаем награду с ожиданием $\mathcal{R}_s^a$.
- Среда выбирает следующее состояние s' по $\mathcal{P}_{ss'}^a$.
- Усредняем $V^\pi(s')$ по переходам, умножаем на γ и добавляем награду.




Белый узел — состояние; чёрный — действие.

$$Q^\pi(s, a) = \mathcal{R}_s^a + \gamma \sum_{s' \in S} \mathcal{P}_{ss'}^a V^\pi(s')$$

Уравнение Беллмана для V^π

Два уровня усреднения.

- Из s выбираем действие по стратегии $\pi(a|s)$.
- Для каждого действия усредняем полезность следующего состояния по $\mathcal{P}_{ss'}^a$.
- Учитываем награду и γ , затем усредняем по действиям: получаем $V^\pi(s)$.




Белый узел — состояние; чёрный — действие.

$$V^\pi(s) = \sum_{a \in A} \pi(a|s) \left(\mathcal{R}_s^a + \gamma \sum_{s' \in S} \mathcal{P}_{ss'}^a V^\pi(s') \right)$$

Уравнение Беллмана для Q^π

От текущего действия — к следующему.


- Текущая пара (s, a) фиксирована; среда переводит нас в s' .
- В s' стратегия выбирает следующее действие a' .
- Усредняем $Q^\pi(s', a')$ по действиям и переходам; учитываем награду и γ .



Белый узел — состояние; чёрный — действие.

$$Q^\pi(s, a) = \mathcal{R}_s^a + \gamma \sum_{s' \in S} \mathcal{P}_{ss'}^a \sum_{a' \in A} \pi(a'|s') Q^\pi(s', a')$$

Алиса: уравнение Беллмана для норы



$$\underbrace{Q^\pi(\text{Нора, за Кроликом})}_{14/3} = -1 + \frac{1}{2} \cdot \frac{4}{3} + \frac{1}{2} \cdot 10$$

$$V^\pi(\text{Нора}) = \underbrace{\frac{1}{2}}_{\text{выбор действия}} (-2 + 10) + \frac{1}{2} \left(-1 + \underbrace{\frac{1}{2} \cdot \frac{4}{3} + \frac{1}{2} \cdot 10}_{\text{случайный переход}} \right) = \frac{19}{3}.$$

Матричная форма уравнения Беллмана для МППР

Уравнение Беллмана с матожиданиями может быть кратко записано:

$$V^\pi = \mathcal{R}^\pi + \gamma \mathcal{P}^\pi V^\pi$$

Аналитическое решение:

$$V^\pi = (I - \gamma \mathcal{P}^\pi)^{-1} \mathcal{R}^\pi$$

Оптимальная функция полезности и стратегия

Оптимальная функция полезности

Определение

Оптимальная функция полезности состояний $V^*(s)$ – это максимальное значение функции полезности по всем стратегиям:


$$V^*(s) = \max_{\pi} V^{\pi}(s).$$

Оптимальная функция полезности действий $Q^*(s, a)$ – это максимальное значение функции полезности по всем стратегиям:

$$Q^*(s, a) = \max_{\pi} Q^{\pi}(s, a).$$

- Оптимальные стратегии характеризуют лучшее поведение в MDP.
- Говорят, что задача MDP решена, когда найдена оптимальная функция полезности.

Алиса: оптимальная полезность V^*



Алиса: оптимальная полезность действий Q^*



Оптимальная стратегия

Определим частичный порядок на множестве стратегий:

$$\pi \geq \pi', \text{ если } V^\pi(s) \geq V^{\pi'}(s), \forall s$$

Теорема

Для любого марковского процесса принятия решений:

- существует оптимальная стратегия π^* , которая лучше или эквивалентна всем другим стратегиям: $\pi^* \geq \pi, \forall \pi$,
- все оптимальные стратегии удовлетворяют оптимальной функции полезности состояний: $V^{\pi^*}(s) = V^*(s)$,
- все оптимальные стратегии удовлетворяют оптимальной функции полезности действий: $Q^{\pi^*}(s, a) = Q^*(s, a)$


Поиск оптимальной стратегии

Оптимальная стратегия π^* может быть найдена максимизацией функции полезности действий $Q^{\pi^*}(s, a)$:

$$\pi^*(a|s) = \begin{cases} 1, & \text{если } a = \arg \max_{a \in A} Q^*(s, a), \\ 0, & \text{иначе} \end{cases}$$

- Для любого MDP существует оптимальная детерминированная стратегия
- Если известна $Q^*(s, a)$, то мы одновременно получаем и оптимальную стратегию


Алиса: оптимальная стратегия



Уравнение Беллмана для V^*

Выбираем лучшее действие.

- В состоянии s сравниваем значения $Q^*(s, a)$ всех доступных действий.
- Выбираем действие с максимальной ожидаемой отдачей.
- Его значение и есть $V^*(s)$. Дуга на дереве обозначает максимум по действиям.



Белый узел — состояние; чёрный — действие.


$$V^*(s) = \max_{a \in A} Q^*(s, a)$$

Уравнение Беллмана для Q^*

После первого действия действуем оптимально.

- Действие a уже задано; оно даёт награду и случайное следующее состояние s' .
- Из s' следуем оптимальной стратегией, поэтому используем $V^*(s')$.
- Усредняем по переходам среды: случайный исход мы не выбираем.

$$Q^*(s, a) = \mathcal{R}_s^a + \gamma \sum_{s' \in S} \mathcal{P}_{ss'}^a V^*(s')$$




Белый узел — состояние; чёрный — действие.

Уравнение Беллмана для V^*

Среднее по исходам, максимум по действиям.

- Для каждого действия считаем награду плюс дисконтированное среднее $V^*(s')$.
- Сравниваем полученные ожидаемые отдачи и выбираем максимум.
- Дуга у верхнего узла — выбор действия; ниже — случайные переходы среды.




Белый узел — состояние; чёрный — действие.

$$V^*(s) = \max_{a \in A} \left(\mathcal{R}_s^a + \gamma \sum_{s' \in S} \mathcal{P}_{ss'}^a V^*(s') \right)$$

Уравнение Беллмана для Q^*

Лучшее продолжение в каждом следующем состоянии.


- После заданного действия a среда выбирает состояние s' .
- В каждом s' выбираем лучшее действие a' : дуги обозначают эти максимумы.
- Усредняем лучшие значения по переходам, учитываем γ и текущую награду.



Белый узел — состояние; чёрный — действие.

$$Q^*(s, a) = \mathcal{R}_s^a + \gamma \sum_{s' \in S} \mathcal{P}_{ss'}^a \max_{a' \in A} Q^*(s', a')$$

Алиса: уравнение оптимальности для норы



$$V^*(\text{Нора}) = \max \left\{ \underbrace{-2 + 10}_{\text{по указателям}}, \underbrace{-1 + \frac{1}{2} \cdot 6 + \frac{1}{2} \cdot 10}_{\text{за Кроликом}} \right\} = \max\{8, 7\} = 8.$$

Максимизируем по действиям; случайные исходы усредняем.

Решение уравнения оптимальности Беллмана

- Уравнение оптимальности Беллмана нелинейно
- Аналитического решения в общем виде не существует
- Много итерационных методов:
 - итерации по полезностям,
 - итерации по стратегии,
 - Q-обучение,
 - SARSA

02

Алгоритм итерации по стратегиям

Требования динамического программирования

Динамическое программирование (dynamic programming, ДП) – очень общий способ решения задач, обладающих двумя свойствами:

- оптимальной структурой:
 - применим принцип оптимальности,
 - оптимальное решение может быть декомпозировано в подзадачи;
- перекрывающиеся подзадачи:
 - подзадачи повторяется многократно,
 - решения могут сохранены и переиспользованы.

Марковский процесс принятия решений удовлетворяет обоим свойствам:

- уравнение Беллмана задает рекурсивную структуру подзадач,
- функция полезности сохраняет и переиспользует решения.

Планирование с помощью ДП

- ДП предполагает использование всей информации о МППР
- В реальных системах используется на этапе планирования
- Для задачи оценки стратегии:

$$\langle S, A, \mathcal{P}, \mathcal{R}, \gamma \rangle \rightarrow V^\pi$$

или

$$\langle S, \mathcal{P}^\pi, \mathcal{R}^\pi, \gamma \rangle \rightarrow V^\pi$$

- Для задачи поиска оптимальной стратегии:

$$\langle S, A, \mathcal{P}, \mathcal{R}, \gamma \rangle \rightarrow \langle V^*, \pi^* \rangle$$

Итерационная оценка стратегии

Задача: оценить текущую стратегию π

Решение: итеративное применение уравнения Беллмана в обратном направлении (Bellman backup):


$$V^1 \rightarrow V^2 \rightarrow \dots \rightarrow V^\pi$$

- Использование *синхронных* шагов:
 - Инициализируем V^1 нулями:
 - для каждой итерации $k + 1$:
 - для каждого состояния $s \in S$:
 - обновить $V^{k+1}(s)$ по $V^k(s')$, где s' – следующее состояние после s
- Можно использовать *асинхронные* шаги
- Сходится к истинным значениям V^π

Итерационная оценка стратегии

Один шаг оценки фиксированной стратегии.


- На листьях — текущие оценки $V^k(s')$.
- Усредняем по переходам среды и действиям стратегии π , учитывая награду и γ .
- В корне получаем новую оценку $V^{k+1}(s)$. Повторяем для всех состояний.



Белый узел — состояние; чёрный — действие.

$$V^{k+1}(s) = \sum_{a \in A} \pi(a|s) \left(\mathcal{R}_s^a + \gamma \sum_{s' \in S} \mathcal{P}_{ss'}^a V^k(s') \right)$$
$$V^{k+1} = \mathcal{R}^\pi + \gamma \mathcal{P}^\pi V^k$$

Пример: случайная стратегия в клеточном мире



- Эпизодический МППР без дисконтирования ($\gamma = 1$)
- Нетерминальные состояния $1, 2, \dots, 14$
- Одно терминальное состояние (серые квадраты)
- Действия, ведущие за пределы карты не меняют состояния
- Агент следует случайной стратегии:

$$\pi(n|\cdot) = \pi(e|\cdot) = \pi(w|\cdot) = \pi(s|\cdot) = 0.25.$$

Пример: случайная стратегия в клеточном мире

$k = 0$

0.0	0.0	0.0	0.0
0.0	0.0	0.0	0.0
0.0	0.0	0.0	0.0
0.0	0.0	0.0	0.0

	↔	↔	↔
↔	↔	↔	↔
↔	↔	↔	↔
↔	↔	↔	

← случайная стратегия

$k = 3$

0.0	-2.4	-2.9	-3.0
-2.4	-2.9	-3.0	-2.9
-2.9	-3.0	-2.9	-2.4
-3.0	-2.9	-2.4	0.0

	←	←	↖
↑	↖	↖	↓
↑	↗	↗	↓
↖	→	→	

оптимальная стратегия

$k = 1$

0.0	-1.0	-1.0	-1.0
-1.0	-1.0	-1.0	-1.0
-1.0	-1.0	-1.0	-1.0
-1.0	-1.0	-1.0	0.0

	←	↔	↔
↑	↔	↔	↔
↔	↔	↔	↓
↔	↔	→	

$k = 10$

0.0	-6.1	-8.4	-9.0
-6.1	-7.7	-8.4	-8.4
-8.4	-8.4	-7.7	-6.1
-9.0	-8.4	-6.1	0.0

	←	←	↖
↑	↖	↖	↓
↑	↗	↗	↓
↖	→	→	

оптимальная стратегия

$k = 2$

0.0	-1.7	-2.0	-2.0
-1.7	-2.0	-2.0	-2.0
-2.0	-2.0	-2.0	-1.7
-2.0	-2.0	-1.7	0.0

	←	←	↔
↑	↖	↖	↓
↑	↗	↗	↓
↖	→	→	

$k = \infty$

0.0	-14.	-20.	-22.
-14.	-18.	-20.	-20.
-20.	-20.	-18.	-14.
-22.	-20.	-14.	0.0

	←	←	↖
↑	↖	↖	↓
↑	↗	↗	↓
↖	→	→	

оптимальная стратегия

Улучшение стратегии

- Дана стратегия π :

- Оценить (evaluate) стратегию π :



$$V^\pi(s) = \mathbb{E}[r_{t+1} + \gamma r_{t+2} + \dots | s_t = s]$$

- Улучшить (improve) стратегию, выбирая действия жадно (greedy), но в соответствии с V^π :

$$\pi' = greedy(V^\pi)$$

- В клеточном мире улучшенная стратегия оказалась оптимальной: $\pi' = \pi^*$
- В общем случае нужно больше итераций
- Однако этот процесс *итерации по стратегии* всегда сходится к оптимальной стратегии π^*

Итерация по стратегиям (Policy Iteration - PI)



Оценка стратегии –

вычисление V^π

Итеративная оценка стратегии

Улучшение стратегии –

генерация $\pi' \geq \pi$

Жадное обновление стратегии

Псевдокод — итерация по стратегиям

Вход: $MDP = \langle \mathcal{S}, \mathcal{A}, P, R, \gamma \rangle$

Псевдокод — итерация по стратегиям

Вход: $MDP = \langle \mathcal{S}, \mathcal{A}, P, R, \gamma \rangle$

1: Инициализировать π и V произвольно

Псевдокод — итерация по стратегиям

Вход: $MDP = \langle \mathcal{S}, \mathcal{A}, P, R, \gamma \rangle$

1: Инициализировать π и V произвольно

2: **repeat**

16: **until** $\Delta\pi = 0$

Псевдокод — итерация по стратегиям

Вход: $MDP = \langle \mathcal{S}, \mathcal{A}, P, R, \gamma \rangle$

1: Инициализировать π и V произвольно

2: **repeat**

3: **repeat**

▷ оценка стратегии

4: **for** каждого $s \in \mathcal{S}$ **do**

5: $V(s) \leftarrow \sum_a \pi(a | s) \sum_{s'} p(s' | s, a) [r(s, a, s') + \gamma V(s')]$

6: **end for**

7: **until** $\Delta V < \theta$

16: **until** $\Delta \pi = 0$

Псевдокод — итерация по стратегиям

Вход: $MDP = \langle \mathcal{S}, \mathcal{A}, P, R, \gamma \rangle$

```
1: Инициализировать  $\pi$  и  $V$  произвольно
2: repeat
3:   repeat ▷ оценка стратегии
4:     for каждого  $s \in \mathcal{S}$  do
5:        $V(s) \leftarrow \sum_a \pi(a | s) \sum_{s'} p(s' | s, a) [r(s, a, s') + \gamma V(s')]$ 
6:     end for
7:   until  $\Delta V < \theta$ 
8:    $stable \leftarrow \text{true}$  ▷ улучшение стратегии
9:   for каждого  $s \in \mathcal{S}$  do
10:     $a_{old} \leftarrow \arg \max_a \pi(a | s)$ 
11:     $\pi(s) \leftarrow \arg \max_a \sum_{s'} p(s' | s, a) [r(s, a, s') + \gamma V(s')]$ 
12:    if  $a_{old} \neq \pi(s)$  then
13:       $stable \leftarrow \text{false}$ 
14:    end if
15:  end for
16: until  $\Delta \pi = 0$ 
```

PI: улучшаем стратегию целиком

Один шаг: оценить текущую стратегию во всех состояниях, затем улучшить действия.

Алиса, $\gamma = 1$

- В зале ищем путь, с чаепития возвращаемся, ворота открываем.
- Начинаем со стратегии, которая в норе идёт за Кроликом.
- После оценки меняем только это действие: идём по указателям.

Как меняется результат из зала

Стратегия	Действие в норе	$V^\pi(\text{Зал})$
Начальная	За Кроликом	4
После улучшения	По указателям	6

Здесь хватило одного улучшения.

Повторная оценка и проверка: менять действия больше не нужно.


Цена шага PI: оценка одной стратегии может потребовать много внутренних проходов.

На другой задаче улучшений может быть больше: результат зависит от начальной стратегии и переходов.

Пример: аренда машин

- *Состояния*: две локации, максимально по 20 машин в каждой
- *Действия*: перегнать до 5 машин в течение ночи между локациями
- *Вознаграждение*: 10\$ за каждую арендованную машину
- *Переходы*: машины возвращаются и арендуются случайно:
 - пуассоновское распределение: n запросов/возвратов с вероятностями $\frac{\lambda^n}{n!}e^{-\lambda}$,
 - 1 локация: среднее кол-во запросов 3, среднее кол-во возвратов 3,
 - 2 локация: среднее кол-во запросов 4, среднее кол-во возвратов 2

Пример: итерация по стратегиям для аренды машин



03

Алгоритм итерации по полезностям

Принцип оптимальности

Любая оптимальная стратегия может быть разделена на две части:

- оптимальный первый шаг a^* ,
- следование оптимальной стратегии, начиная со следующего состояния s' .

Теорема Принцип оптимальности

Стратегия $\pi(a|s)$ достигает оптимальной оценки состояния s $V^\pi(s) = V^*(s)$, если и только если для любого s' , достижимого из s , π достигает оптимальной оценки состояния s' : $V^\pi(s') = V^*(s')$.

Детерминированные итерации по полезностям

- Пусть мы знаем решение для подзадачи $V^*(s')$,
- тогда мы можем найти решение за один шаг:

$$V^*(s) \leftarrow \max_{a \in A} \left(\mathcal{R}_s^a + \gamma \sum_{s' \in S} \mathcal{P}_{ss'}^a V^*(s') \right)$$

- Идея итераций по полезностям – применять эти обновления рекурсивно.
- *Интуиция*: начать с конечных вознаграждений и двигаться назад.

Пример: кратчайший путь

g			

Problem

0	0	0	0
0	0	0	0
0	0	0	0
0	0	0	0

V_1

0	-1	-1	-1
-1	-1	-1	-1
-1	-1	-1	-1
-1	-1	-1	-1

V_2

0	-1	-2	-2
-1	-2	-2	-2
-2	-2	-2	-2
-2	-2	-2	-2

V_3

0	-1	-2	-3
-1	-2	-3	-3
-2	-3	-3	-3
-3	-3	-3	-3

V_4

0	-1	-2	-3
-1	-2	-3	-4
-2	-3	-4	-4
-3	-4	-4	-4

V_5

0	-1	-2	-3
-1	-2	-3	-4
-2	-3	-4	-5
-3	-4	-5	-5

V_6

0	-1	-2	-3
-1	-2	-3	-4
-2	-3	-4	-5
-3	-4	-5	-6

V_7

Итерация по полезностям

Задача: найти оптимальную стратегию π^* .

Решение: итеративное применение уравнения **оптимальности** Беллмана в обратном направлении:


$$V^1 \rightarrow V^2 \rightarrow \dots \rightarrow V^*$$

- Использование *синхронных* шагов:
 - для каждой итерации $k + 1$:
 - для каждого состояния $s \in S$
 - обновить $V^{k+1}(s)$ по $V^k(s')$, где s' – следующее состояние после s с оператором максимума по действиям
- Сходится к истинным значениям V^* .
- В отличие от итерации по стратегиям мы не получаем стратегию в явном виде.
- Промежуточные значения полезностей могут не соответствовать ни одной стратегии.

Итерация по полезностям

Один шаг поиска оптимальных полезностей.

- По текущим $V^k(s')$ оцениваем ожидаемую отдачу каждого действия.
- В корне берём максимум по действиям и получаем $V^{k+1}(s)$.
- Применяем это обновление ко всем состояниям: это оператор Беллмана $\mathcal{B}$.



Белый узел — состояние; чёрный — действие.

$$V^{k+1}(s) = \max_{a \in A} \left(\mathcal{R}_s^a + \gamma \sum_{s' \in S} \mathcal{P}_{ss'}^a V^k(s') \right)$$

$$V^{k+1} = \max_{a \in A} \left(\mathcal{R}^a + \gamma \mathcal{P}^a V^k \right)$$

$V^{k+1} = \mathcal{B}V^k$ — оператор Беллмана (Bellman backup operator)

Псевдокод — итерация по полезностям

Вход: порог сходимости θ , коэффициент дисконтирования γ

Псевдокод — итерация по полезностям

Вход: порог сходимости θ , коэффициент дисконтирования γ

1: Инициализировать $V(s)$ произвольно для всех $s \in \mathcal{S}$

Псевдокод — итерация по полезностям

Вход: порог сходимости θ , коэффициент дисконтирования γ

1: Инициализировать $V(s)$ произвольно для всех $s \in \mathcal{S}$

2: **repeat**

3: $\Delta \leftarrow 0$

9: **until** $\Delta < \theta$

▷ порог сходимости

Псевдокод — итерация по полезностям

Вход: порог сходимости θ , коэффициент дисконтирования γ

1: Инициализировать $V(s)$ произвольно для всех $s \in \mathcal{S}$

2: **repeat**

3: $\Delta \leftarrow 0$

4: **for** каждого $s \in \mathcal{S}$ **do**

5: $v \leftarrow V(s)$

6: $V(s) \leftarrow \max_a \sum_{s',r} p(s',r \mid s,a) [r + \gamma V(s')]$

▷ оператор Беллмана

7: $\Delta \leftarrow \max(\Delta, |v - V(s)|)$

8: **end for**

9: **until** $\Delta < \theta$

▷ порог сходимости

Псевдокод — итерация по полезностям

Вход: порог сходимости θ , коэффициент дисконтирования γ

```
1: Инициализировать  $V(s)$  произвольно для всех  $s \in \mathcal{S}$ 
2: repeat
3:    $\Delta \leftarrow 0$ 
4:   for каждого  $s \in \mathcal{S}$  do
5:      $v \leftarrow V(s)$ 
6:      $V(s) \leftarrow \max_a \sum_{s',r} p(s', r \mid s, a) [r + \gamma V(s')]$ 
7:      $\Delta \leftarrow \max(\Delta, |v - V(s)|)$ 
8:   end for
9: until  $\Delta < \theta$ 
10:  $\pi(s) \leftarrow \arg \max_a \sum_{s',r} p(s', r \mid s, a) [r + \gamma V(s')]$ 
11: return  $\pi, V$ 
```

▷ оператор Беллмана

▷ порог сходимости

▷ жадная стратегия

VI: полезность распространяется шаг за шагом

Один проход: обновить все состояния по таблице предыдущего прохода.

Та же Алиса, $\gamma = 1$

- Начинаем с нулевых полезностей; полезность сада всегда 0.
- Сначала учитываем награду у ворот, затем её влияние доходит до норы и зала.
- На четвёртом проходе получаем V^* во всех состояниях.

Полезности после каждого прохода

Проход	Ворота	Нора	Зал	Чаепитие
0	0	0	0	0
1	10	-1	1	-1
2	10	8	0	-2
3	10	8	6	-3
4	10	8	6	3

Синим — момент, когда полезность стала оптимальной и больше не меняется.

Скорость VI: за один синхронный проход информация проходит один переход назад. Поэтому далёкие последствия требуют многих проходов.

Скорость сходимости: VI и PI

VI: один шаг — один проход

Один проход обновлений; далёкие последствия требуют многих проходов.

PI: один шаг — оценка и улучшение

Шагов может быть меньше, но каждый включает оценку всей стратегии.

Для обоих методов при $0 < \gamma < 1$: ошибка после шага не больше γ от прежней ошибки. Для PI нужна точная оценка стратегии.

	Начало		Шаг 1		Шаг 2
$\gamma = 0.5$	100	→	50	→	25
$\gamma = 0.9$	100	→	90	→	81

Верхние границы максимальной ошибки, в условных единицах; начальная граница равна 100.

Чем ближе γ к 1, тем слабее гарантия скорости для обоих методов.

VI и PI: сколько вычислений?

$n = |S|$ — число состояний, $m = |A|$ — число действий. Рассматриваем плотную модель переходов и $0 < \gamma < 1$.

$$L = \frac{1}{1 - \gamma} \log \frac{1}{\varepsilon}, \quad \varepsilon \text{ — требуемая доля начальной ошибки.}$$

Простая верхняя оценка: число шагов $\times$ работа за шаг.

	VI	PI с точной оценкой
Число шагов	$O(L)$	$O(L)$
Работа за шаг	$O(n^2m)$	$O(n^3 + n^2m)$
Всего вычислений	$O(n^2mL)$	$O((n^3 + n^2m)L)$

- n^2m : для каждого состояния и действия суммируем по следующим состояниям.
- n^3 : оцениваем стратегию PI, решая систему из n уравнений методом исключения.

Для VI шаг — полный проход; для PI — точная оценка и улучшение стратегии.

Итоги: от планирования к обучению

Сегодня мы планировали, зная модель среды: вероятности переходов $\mathcal{P}$ и ожидаемые награды $\mathcal{R}$.

Что умеем с известной моделью

- **Оценивать стратегию:** вычислять её полезность V^π .
- **PI:** оценивать стратегию и улучшать действия.
- **VI:** обновлять полезности с максимумом по действиям, затем извлекать стратегию.

В обновлении Беллмана считаем среднее по возможным переходам из модели.

Дальше: модель неизвестна

Взаимодействуем со средой и наблюдаем опыт:

$$(s_t, a_t, r_{t+1}, s_{t+1}).$$

- **Монте-Карло:** оцениваем полезность по отдам завершённых эпизодов.
- **TD:** обновляем оценку после перехода, используя награду и оценку следующего состояния.

Следующий шаг — учиться по опыту, не имея готовых $\mathcal{P}$ и $\mathcal{R}$.

Идея полезности сохраняется; способ её оценки меняется.

Вопросы?