

Компромисс между смещением и дисперсией
Обобщенная оценка преимущества
Метод оптимизации ближайшей стратегии

Алексей Скрынник

ПЛАН

01 Оценка преимущества и GAE

02 Суррогатная цель

03 Метод PPO

04 Применения PPO

01

Оценка преимуществ и GAE

Напоминание: градиент стратегии

$$J(\pi_\theta) := \mathbb{E}_{\tau \sim \pi_\theta} \left[\sum_{t=0}^{\infty} \gamma^t r_t \right]$$

$$\nabla_\theta J(\pi_\theta) = \underbrace{\mathbb{E}_{\tau \sim \pi_\theta}}_{\text{траектории текущей стратегии}} \left[\sum_{t=0}^{\infty} \gamma^t \underbrace{\nabla_\theta \log \pi_\theta(a_t \mid s_t)}_{\text{градиент логарифма вероятности}} \underbrace{\left(Q^{\pi_\theta}(s_t, a_t) - \underbrace{V^{\pi_\theta}(s_t)}_{\text{базовый уровень}} \right)}_{A^{\pi_\theta}(s_t, a_t)} \right]$$

- **Критик:** обучаемая аппроксимация $V_\phi(s) \approx V^{\pi_\theta}(s)$.
- Одношаговая бутстрэп-оценка полезности действия:

$$Q^{\pi_\theta}(s_t, a_t) \approx y_t^Q = r_t + \gamma V_\phi(s_{t+1}).$$

- **Бутстрэппинг может вносить смещение**, если критик неточен.

Компромисс между смещением и дисперсией

Даны траектория стратегии π и критик V_ϕ . Как оценить, насколько удачным было действие a_t в состоянии s_t ?

Для актора:

$$\hat{g}_t = \nabla_{\theta} \log \pi_{\theta}(a_t \mid s_t) \underbrace{\Psi_t}_{\text{оценка преимущества}}.$$

Для критика:

$$\underbrace{y_t^Q}_{\text{цель регрессии}} = \Psi_t + V_{\phi}(s_t).$$

	Оценка преимущества Ψ_t	Смещение*	Дисперсия
Монте-Карло	$\sum_{l=0}^{T-t-1} \gamma^l r_{t+l} - V_{\phi}(s_t)$	нет	высокая
n шагов	$\sum_{l=0}^{n-1} \gamma^l r_{t+l} + \gamma^n V_{\phi}(s_{t+n}) - V_{\phi}(s_t)$	среднее	средняя
Один шаг	$r_t + \gamma V_{\phi}(s_{t+1}) - V_{\phi}(s_t)$	высокое	низкая

Проблема: как выбрать число шагов n ?

*Смещение оценки градиента стратегии; базовый уровень не зависит от действия. Указаны типичные тенденции при неточном критике. T — конец эпизода, $V_{\phi}(s_T) = 0$.

Напоминание: TD(λ)

Трудно выбрать число шагов? Усредним оценки.


Оценка	Вес
$\Psi_t^{(1)}$	$1 - \lambda$
$\Psi_t^{(2)}$	$(1 - \lambda)\lambda$
$\Psi_t^{(3)}$	$(1 - \lambda)\lambda^2$
$\vdots$	$\vdots$

Обобщенная оценка преимущества:

$$\hat{A}_t^{\text{GAE}} = (1 - \lambda) \sum_{n=1}^{\infty} \lambda^{n-1} \Psi_t^{(n)}.$$

- $\lambda = 0$: одношаговая TD-оценка.
- $\lambda \rightarrow 1$: большой вес длинных возвратов.

Для конечного эпизода оставшийся вес λ^{T-t-1} получает полный возврат. При $\lambda = 1$ получаем оценку Монте-Карло.




$$G_t^\lambda = (1 - \lambda) \sum_{n=1}^{T-t-1} \lambda^{n-1} G_{t:t+n} + \lambda^{T-t-1} G_t$$

Дисконтированная сумма TD-ошибок

Обозначим одношаговую TD-ошибку:

$$\delta_t = \Psi_t^{(1)} = r_t + \gamma V_\phi(s_{t+1}) - V_\phi(s_t).$$



Промежуточные оценки полезности сокращаются:

$$\begin{aligned}\delta_t + \gamma\delta_{t+1} &= r_t + \gamma V_\phi(s_{t+1}) - V_\phi(s_t) + \gamma r_{t+1} + \gamma^2 V_\phi(s_{t+2}) - \gamma V_\phi(s_{t+1}) \\ &= r_t + \gamma r_{t+1} + \gamma^2 V_\phi(s_{t+2}) - V_\phi(s_t) = \Psi_t^{(2)}.\end{aligned}$$

$$\Psi_t^{(n)} = \sum_{l=0}^{n-1} \gamma^l \delta_{t+l}$$

Многошаговая оценка — дисконтированная сумма одношаговых ошибок.

Обобщенная оценка преимущества (GAE)

Эквивалентная форма: сумма TD-ошибок

$$\underbrace{(1 - \lambda) \sum_{n=1}^{\infty} \lambda^{n-1} \Psi_t^{(n)}}_{\text{смесь многошаговых оценок}} = \underbrace{\sum_{l=0}^{\infty} (\gamma \lambda)^l \delta_{t+l}}_{\text{взвешенные TD-ошибки}}.$$

Если доступны только H переходов:


$$\hat{A}_t^{\text{GAE}} = \sum_{l=0}^{H-1} (\gamma \lambda)^l \delta_{t+l}.$$

На практике: обратный проход по фрагменту

$$\delta_t = r_t + \gamma(1 - d_{t+1})V_{\phi}(s_{t+1}) - V_{\phi}(s_t),$$

$$\boxed{\hat{A}_t = \delta_t + \gamma \lambda (1 - d_{t+1}) \hat{A}_{t+1}}.$$

$d_{t+1} = 1$ при завершении эпизода. На границе фрагмента задаём $\hat{A}_{t+H} = 0$; если эпизод продолжается, сохраняем бутстрэп из $V_{\phi}(s_{t+H})$.



$$G_t^\lambda = (1 - \lambda) \sum_{n=1}^{T-t-1} \lambda^{n-1} G_{t:t+n} + \lambda^{T-t-1} G_t$$

От траекторий к отдельным переходам

Отправная точка: градиент стратегии — ожидаемая сумма вкладов всех шагов траектории:

$$\nabla_{\theta} J(\pi_{\theta}) = \mathbb{E}_{\tau \sim \pi_{\theta}} \left[\sum_{t=0}^{\infty} \gamma^t \underbrace{\nabla_{\theta} \log \pi_{\theta}(a_t | s_t) A^{\pi_{\theta}}(s_t, a_t)}_{f_{\theta}(s_t, a_t)} \right].$$


Что хотим на практике?

- Собрать фрагменты траекторий в нескольких средах.
- Для каждого перехода оценить преимущество через GAE.
- Усреднить вклады $f_{\theta}(s, a)$ по выборке.

Чего пока не хватает? Распределения, из которого нужно брать пары (s, a) .

Частые состояния должны встречаться чаще; поздние шаги имеют меньший вес из-за γ^t .

Задача: переписать ожидаемую сумму по времени как среднее по состояниям и действиям.



Как часто учитывать каждое состояние?

Для краткости обозначим вклад пары (s, a) через $f(s, a)$, а текущую стратегию — через π .

1. Раскроем ожидание на каждом шаге t :

$$\mathbb{E}_{\tau \sim \pi} \left[\sum_{t=0}^{\infty} \gamma^t f(s_t, a_t) \right] = \sum_{t=0}^{\infty} \gamma^t \sum_s \mathbb{P}(s_t = s \mid \pi) \sum_a \pi(a \mid s) f(s, a).$$

2. Соберём вместе все посещения одного и того же состояния:

$$= \sum_s \underbrace{\left[\sum_{t=0}^{\infty} \gamma^t \mathbb{P}(s_t = s \mid \pi) \right]}_{\rho_{\pi}(s)} \sum_a \pi(a \mid s) f(s, a).$$

$\rho_{\pi}(s)$ — **ожидаемое число посещений s с весами γ^t .**

Например, если состояние s встречается на шагах 0 и 2, эта траектория даёт ему вес $1 + \gamma^2$.

Это веса, а не вероятности: одно состояние может посещаться много раз. Нормировка превратит ρ_{π} в распределение d_{π} .

Нормировка дисконтированных посещений

1. Суммируем посещения с весами γ^t .

$\rho_\pi(s) := \sum_{t=0}^{\infty} \gamma^t \mathbb{P}(s_t = s \mid \pi)$, где $0 \leq \gamma < 1$. Суммарный вес равен:

$$\sum_s \rho_\pi(s) = \sum_{t=0}^{\infty} \gamma^t \underbrace{\sum_s \mathbb{P}(s_t = s \mid \pi)}_{=1} = \sum_{t=0}^{\infty} \gamma^t = \frac{1}{1-\gamma}.$$

2. Нормируем: делим на суммарный вес.

$$d_\pi(s) = \frac{\rho_\pi(s)}{1/(1-\gamma)} = (1-\gamma)\rho_\pi(s), \quad \sum_s d_\pi(s) = 1.$$

3. Подставляем $\rho_\pi(s) = d_\pi(s)/(1-\gamma)$ в ожидание:

$$\begin{aligned} \mathbb{E}_{\tau \sim \pi} \left[\sum_{t=0}^{\infty} \gamma^t f(s_t, a_t) \right] &= \sum_s \rho_\pi(s) \sum_a \pi(a \mid s) f(s, a) \\ &= \frac{1}{1-\gamma} \mathbb{E}_{s \sim d_\pi, a \sim \pi(\cdot \mid s)} [f(s, a)]. \end{aligned}$$

Для непрерывных состояний и действий суммы заменяются интегралами. После конца эпизода считаем состояние поглощающим, а $f = 0$.

Сбор данных в A2C

Можно ли оценивать градиент стратегии, **не дожидаясь конца эпизода?**

Дисконтированное распределение посещений состояний:

$$d_{\pi}(s) = (1 - \gamma) \sum_{t=0}^{\infty} \gamma^t \mathbb{P}(s_t = s \mid \pi), \quad 0 \leq \gamma < 1.$$

$$\mathbb{E}_{\tau \sim \pi} \left[\sum_{t=0}^{\infty} \gamma^t f(s_t, a_t) \right] = \frac{1}{1 - \gamma} \mathbb{E}_{s \sim d_{\pi}, a \sim \pi(\cdot | s)} [f(s, a)].$$

Главное: градиент можно оценивать по парам состояний и действий.

$$\nabla_{\theta} J(\pi_{\theta}) = \frac{1}{1 - \gamma} \mathbb{E}_{s \sim d_{\pi_{\theta}}, a \sim \pi_{\theta}} [\nabla_{\theta} \log \pi_{\theta}(a \mid s) A^{\pi_{\theta}}(s, a)].$$

- Собираем фрагменты траекторий текущей стратегией; на границе фрагмента используем оценку критика.
- **Соседние переходы коррелированы.** Параллельные среды помогают разнообразить выборку.

Равномерная выборка переходов в A2C лишь приближает дисконтированное распределение d_{π} .

02



Суррогатная цель

GAE в методе актер–критик A2C

Длиннее фрагмент — богаче смесь GAE.

$$\hat{A}_t = \sum_{l=0}^{H-1} (\gamma \lambda)^l \delta_{t+l}.$$


- λ регулирует компромисс между смещением и дисперсией.
- Длина H определяет, насколько далеко видны последствия действия.
- При фиксированном размере выборки рост H уменьшает число независимых сред.

Для коротких фрагментов A2C можно выбрать $\lambda = 1$:

$$\hat{A}_t = \sum_{l=0}^{H-1} \gamma^l r_{t+l} + \gamma^H V_\phi(s_{t+H}) - V_\phi(s_t).$$

Это H -шаговая оценка с бутстрэппингом; она становится оценкой Монте-Карло, если фрагмент заканчивается вместе с эпизодом.

Цикл A2C



Методы полезности и градиент стратегии

Методы полезности: DQN и расширения

Обучаем $Q^*(s, a)$, затем выбираем действие по оценке полезности.

Для исследования нужен отдельный механизм, например ϵ -жадная стратегия.

В базовом DQN — одношаговая TD-цель. Многошаговые расширения требуют учитывать off-policy данные.

Off-policy: повторно используем переходы из буфера воспроизведения.

Градиент стратегии: A2C

Напрямую обучаем $\pi_\theta(a | s)$; критик приближает $V^{\pi_\theta}(s)$.

Стохастическая стратегия сама задаёт распределение действий; энтропийный бонус поддерживает исследование.

Многошаговые оценки и GAE естественно используются для обучения актора и критика.

On-policy: в стандартном A2C после обновления собираем новые данные текущей стратегией.

Следующий шаг: повторно использовать выборку при обучении стратегии.

Градиент стратегии по данным старой стратегии?


Для текущей стратегии точный градиент имеет вид:

$$\nabla_{\theta} J(\pi_{\theta}) = \frac{1}{1 - \gamma} \mathbb{E}_{s \sim d_{\pi_{\theta}}, a \sim \pi_{\theta}(\cdot | s)} [\nabla_{\theta} \log \pi_{\theta}(a | s) A^{\pi_{\theta}}(s, a)] .$$

Что у нас есть?

- Траектории, собранные π^{old} .
- Выборка состояний из $d_{\pi^{\text{old}}}$ и действий из $\pi^{\text{old}}(\cdot | s)$.
- Критик $V_{\phi} \approx V^{\pi^{\text{old}}}$; через GAE оцениваем $A^{\pi^{\text{old}}}$.

Что хотим? Оптимизировать новую стратегию π_{θ} на уже собранных данных.



Можно ли выразить $J(\pi_{\theta})$ через преимущество старой стратегии $A^{\pi^{\text{old}}}$?

Связываем две стратегии: телескопическая сумма

Идея: добавим к награде разность полезностей состояний, вычисленных для другой стратегии.

Для любой последовательности $b_t \rightarrow 0$ промежуточные члены сокращаются:

$$\sum_{t=0}^{T-1} (b_{t+1} - b_t) = \underbrace{(b_1 - b_0) + (b_2 - b_1) + \dots + (b_T - b_{T-1})}_{b_T - b_0} \xrightarrow{T \rightarrow \infty} -b_0.$$

Подставим $b_t = \gamma^t V^{\pi^{\text{old}}}(s_t)$:

$$\boxed{\sum_{t=0}^{\infty} \gamma^t \left[\gamma V^{\pi^{\text{old}}}(s_{t+1}) - V^{\pi^{\text{old}}}(s_t) \right] = -V^{\pi^{\text{old}}}(s_0)}.$$

Определим преобразованную награду:

$$\tilde{r}_t = r_t + \gamma V^{\pi^{\text{old}}}(s_{t+1}) - V^{\pi^{\text{old}}}(s_t), \quad \sum_{t=0}^{\infty} \gamma^t \tilde{r}_t = \sum_{t=0}^{\infty} \gamma^t r_t - V^{\pi^{\text{old}}}(s_0).$$

Равенство верно для любой траектории, даже если её генерирует новая стратегия π_θ .

При $0 \leq \gamma < 1$ достаточно ограниченности V . В конечном эпизоде полагаем $V(s_T) = 0$.

Разность полезностей двух стратегий

Траекторию генерирует π_θ ; полезности оцениваем относительно π^{old} .

Обозначим $V^{\text{old}} := V^{\pi^{\text{old}}}$ и $\mathbb{E}_\theta[\cdot] := \mathbb{E}_{\tau \sim \pi_\theta | s_0=s}[\cdot]$.

$$\begin{aligned} V^{\pi_\theta}(s) - V^{\text{old}}(s) &= \mathbb{E}_\theta \left[\sum_{t=0}^{\infty} \gamma^t r_t - V^{\text{old}}(s_0) \right] \\ &= \mathbb{E}_\theta \left[\sum_{t=0}^{\infty} \gamma^t (r_t + \gamma V^{\text{old}}(s_{t+1}) - V^{\text{old}}(s_t)) \right]. \end{aligned}$$

Последнее равенство использует телескопическую сумму. Усредним по награде и следующему состоянию при фиксированных s_t, a_t :

$$\mathbb{E}[r_t + \gamma V^{\text{old}}(s_{t+1}) \mid s_t, a_t] = Q^{\pi^{\text{old}}}(s_t, a_t).$$

$$\boxed{V^{\pi_\theta}(s) - V^{\pi^{\text{old}}}(s) = \mathbb{E}_{\tau \sim \pi_\theta | s_0=s} \left[\sum_{t=0}^{\infty} \gamma^t A^{\pi^{\text{old}}}(s_t, a_t) \right]}$$

Улучшение стратегии — ожидаемая сумма старых преимуществ вдоль **новой** траектории.

От разности полезностей к разности отдач

Усредним полученное равенство по **одному и тому же** начальному распределению $s_0 \sim p_0$:

$$J(\pi_\theta) - J(\pi^{\text{old}}) = \mathbb{E}_{\tau \sim \pi_\theta} \left[\sum_{t=0}^{\infty} \gamma^t A^{\pi^{\text{old}}}(s_t, a_t) \right].$$

Применим уже выведенную формулу для дисконтированных посещений:

$$J(\pi_\theta) - J(\pi^{\text{old}}) = \frac{1}{1 - \gamma} \mathbb{E}_{\substack{s \sim d_{\pi_\theta} \\ a \sim \pi_\theta(\cdot | s)}} [A^{\pi^{\text{old}}}(s, a)].$$

- **Уже можем оценить:** преимущество старой стратегии с помощью критика и GAE.
- **Пока не можем напрямую усреднить:** состояния и действия в формуле генерирует новая стратегия.
- Данные собраны π^{old} , поэтому отличаются **два распределения:** $d_{\pi_\theta}(s)$ и $\pi_\theta(a | s)$.

Сначала скорректируем действия, затем разберёмся с состояниями.

Как использовать действия старой стратегии?

Зафиксируем состояние s . Меняем распределение действий с помощью отношения вероятностей:

$$\begin{aligned}\mathbb{E}_{a \sim \pi_\theta(\cdot | s)}[A^{\pi^{\text{old}}}(s, a)] &= \sum_a \pi_\theta(a | s) A^{\pi^{\text{old}}}(s, a) \\ &= \sum_a \pi^{\text{old}}(a | s) \underbrace{\frac{\pi_\theta(a | s)}{\pi^{\text{old}}(a | s)}}_{w_\theta(s, a)} A^{\pi^{\text{old}}}(s, a) \\ &= \mathbb{E}_{a \sim \pi^{\text{old}}(\cdot | s)}[w_\theta(s, a) A^{\pi^{\text{old}}}(s, a)].\end{aligned}$$

Пример: вероятность выросла с 0.2 до 0.4 — вклад действия умножаем на 2.

- Это **выборка по значимости** (importance sampling).
- Требуется $\pi^{\text{old}}(a | s) > 0$ там, где $\pi_\theta(a | s) > 0$.
- Исправили распределение действий, но не состояний: в точной формуле всё ещё стоит $s \sim d_{\pi_\theta}$.

Суррогатная целевая функция

Локальное приближение: считаем, что распределение посещений изменилось мало, и заменяем d_{π_θ} на $d_{\pi^{\text{old}}}$.

$$J(\pi_\theta) - J(\pi^{\text{old}}) \approx L_{\pi^{\text{old}}}(\theta) := \frac{1}{1 - \gamma} \mathbb{E}_{\substack{s \sim d_{\pi^{\text{old}}} \\ a \sim \pi^{\text{old}}(\cdot | s)}} \left[\underbrace{\frac{\pi_\theta(a | s)}{\pi^{\text{old}}(a | s)}}_{w_\theta(s, a)} A^{\pi^{\text{old}}}(s, a) \right].$$

Теперь все данные и оценки преимущества относятся к старой стратегии.

$$\hat{L}(\theta) = \frac{1}{(1 - \gamma)N} \sum_{i=1}^N w_\theta(s_i, a_i) \hat{A}_i^{\text{old}}.$$

- При $\hat{A}_i^{\text{old}} > 0$ увеличиваем вероятность действия; при $\hat{A}_i^{\text{old}} < 0$ — уменьшаем.
- При $\pi_\theta = \pi^{\text{old}}$ точная цель равна нулю, а её градиент совпадает с градиентом J .
- Слишком большой шаг разрушает приближение: новая стратегия посещает другие состояния.

Фиксируем π^{old} и $\hat{A}_i^{\text{old}}$. Постоянный множитель $1/(1 - \gamma)$ можно поглотить скоростью обучения.

Насколько точна суррогатная цель?

Заменяв d_{π_θ} на $d_{\pi^{\text{old}}}$, мы внесли ошибку. Она контролируется **изменением стратегии**:

$$\left| J(\pi_\theta) - J(\pi^{\text{old}}) - L_{\pi^{\text{old}}}(\theta) \right| \leq C D_{\text{KL}}^{\text{max}}(\pi^{\text{old}} \parallel \pi_\theta).$$

Здесь берём максимальное KL-расхождение по всем состояниям:

$$D_{\text{KL}}^{\text{max}}(\pi^{\text{old}} \parallel \pi_\theta) := \max_s D_{\text{KL}}(\pi^{\text{old}}(\cdot \mid s) \parallel \pi_\theta(\cdot \mid s)),$$

$$D_{\text{KL}}(p \parallel q) = \sum_a p(a) \log \frac{p(a)}{q(a)}, \quad C = \frac{4\gamma\epsilon}{(1-\gamma)^2}, \quad \epsilon = \max_{s,a} |A^{\pi^{\text{old}}}(s, a)|.$$

- Малое изменение стратегии во всех состояниях ограничивает ошибку приближения.
- Отсюда получаем **нижнюю границу улучшения**:

$$J(\pi_\theta) - J(\pi^{\text{old}}) \geq L_{\pi^{\text{old}}}(\theta) - C D_{\text{KL}}^{\text{max}}(\pi^{\text{old}} \parallel \pi_\theta).$$

Условия: $\gamma < 1$, ограниченное преимущество, точные ожидания и одинаковое начальное распределение состояний.

Улучшаем стратегию через нижнюю границу

$$J(\pi_\theta) - J(\pi^{\text{old}}) \geq \underbrace{L_{\pi^{\text{old}}}(\theta) - C D_{\text{KL}}^{\text{max}}(\pi^{\text{old}} \parallel \pi_\theta)}_{B(\theta)}.$$

В текущей точке граница точна: $B(\theta_{\text{old}}) = 0$.

1. Фиксируем π^{old} и строим нижнюю границу.
2. Увеличиваем $B(\theta)$, начиная с θ_{old} .
3. Принимаем новую стратегию и повторяем.


Если $B(\theta) \geq 0$, то $J(\pi_\theta) \geq J(\pi^{\text{old}})$.

Проблема: теоретический C слишком велик. Штраф подавляет даже полезные изменения стратегии.


При $\gamma = 0.99$ получаем $C = 39600 \epsilon$.

Гарантия относится к точной границе. Оценки по конечной выборке сами по себе её не обеспечивают.

Умеренный штраф



Большой штраф



Схематическая иллюстрация.

03



Метод PPO

Оптимизация в доверительной области


Идея: увеличиваем суррогатную цель, но ограничиваем отличие новой стратегии от старой.

$$\max_{\theta} L_{\pi^{\text{old}}}(\theta),$$

$$\text{при } \mathbb{E}_{s \sim d_{\pi^{\text{old}}}} [D_{\text{KL}}(\pi^{\text{old}}(\cdot | s) \| \pi_{\theta}(\cdot | s))] \leq \delta.$$

- L — локальная модель улучшения.
- δ задаёт размер доверительной области, внутри которой используем эту модель.
- TRPO приближённо решает задачу с ограничением; реализация сложнее обычного SGD.

Здесь ограничено среднее KL, а в теореме фигурировало максимальное. Это практическое приближение к теоретической постановке.



Ограничиваем изменение распределения действий, а не евклидово расстояние между параметрами сети.

PPO: несколько обновлений на одной выборке


В A2C: собрали фрагменты, сделали одно обновление, затем собрали новые данные.

В PPO: собираем большую выборку и используем её несколько эпох, контролируя изменение стратегии.

- Сохраняем $\log \pi^{\text{old}}(a_t | s_t)$, старые оценки критика и преимущества GAE.
- Перемешиваем переходы и обновляем параметры по мини-батчам.
- π^{old} и преимущества остаются фиксированными на протяжении всех эпох.

Два способа контролировать шаг: KL-штраф или клиппированная цель. Далее используем **PPO-Clip**.

Одних градиентных шагов недостаточно: без контроля стратегия может слишком далеко уйти от стратегии сбора данных.



Клиппированная целевая функция PPO

Отношение вероятностей показывает, насколько изменилось действие:

$$w_{\theta}(s, a) = \frac{\pi_{\theta}(a \mid s)}{\pi^{\text{old}}(a \mid s)}, \quad w_{\theta} = 1 \text{ в начале обновления.}$$

Обычный вклад в суррогатную цель: $w_{\theta} \hat{A}^{\text{old}}$. Ограничим отношение в дополнительной ветви:

$$\bar{w}_{\theta} = \text{clip}(w_{\theta}, 1 - \epsilon, 1 + \epsilon), \quad \epsilon = 0.2 \Rightarrow [0.8, 1.2].$$

PPO-Clip берёт меньший из двух вкладов:

$$L^{\text{clip}}(\theta) = \mathbb{E}_{(s,a) \sim \text{data}_{\text{old}}} \left[\min \left(w_{\theta} \hat{A}^{\text{old}}, \bar{w}_{\theta} \hat{A}^{\text{old}} \right) \right] \longrightarrow \max_{\theta}.$$

- Клиппирование только w_{θ} обнуляет градиент с обеих сторон, даже при ухудшении действия.
- Минимум даёт консервативный вклад: $\ell^{\text{clip}} \leq w_{\theta} \hat{A}^{\text{old}}$.
- Нижняя граница относится к **суррогатной цели**, а не к истинному улучшению J .

Старые вероятности и преимущества фиксированы. Постоянный множитель $1/(1 - \gamma)$ опущен.

Почему в PPO нужен минимум?

Для одного перехода положим $A = \hat{A}^{\text{old}}$, $w = \pi_{\theta}(a \mid s) / \pi^{\text{old}}(a \mid s)$.


$$\ell^{\text{clip}}(w, A) = \min(wA, \text{clip}(w, 1 - \epsilon, 1 + \epsilon)A) = \begin{cases} A \min(w, 1 + \epsilon), & A \geq 0, \\ A \max(w, 1 - \epsilon), & A < 0. \end{cases}$$

При $\epsilon = 0.2$:

Знак A	Хотим	Отношение w	$\partial \ell / \partial w$
$A > 0$	$\pi_{\theta} \uparrow$	$w > 1.2$	0
$A > 0$	$\pi_{\theta} \uparrow$	$w < 0.8$	A
$A < 0$	$\pi_{\theta} \downarrow$	$w > 1.2$	A
$A < 0$	$\pi_{\theta} \downarrow$	$w < 0.8$	0

Убираем стимул к чрезмерному улучшению этого перехода, но сохраняем сигнал, исправляющий ухудшение.

Внутри интервала производная равна A . При $A = 0$ вклад равен нулю.



Слева — KL-ограничение; справа — одностороннее действие клиппинга. Геометрия показана схематически.

Клиппинг не гарантирует ни $w \in [0.8, 1.2]$, ни малое KL.

Клиппинг функции потерь критика

Фиксируем старую оценку $V^{\text{old}}(s)$ и цель $y = \hat{A}^{\text{old}}(s, a) + V^{\text{old}}(s)$ на время обновлений.

Обычная регрессия:

$$\ell_V(\phi) = (V_\phi(s) - y)^2.$$

Ограничим изменение **предсказания в функции потерь**:


$$V_\phi^{\text{clip}}(s) = V^{\text{old}}(s) + \text{clip}(V_\phi(s) - V^{\text{old}}(s), -\epsilon_V, \epsilon_V).$$

Возьмём более консервативную из двух ошибок:

$$\ell_V^{\text{PPO}}(\phi) = \max \left\{ (V_\phi(s) - y)^2, (V_\phi^{\text{clip}}(s) - y)^2 \right\}.$$

- ϵ_V задаётся в единицах полезности; масштаб награды имеет значение.
- Это дополнительный приём; PPO можно использовать с обычной ошибкой критика.

Пример: $v = V_\phi(s)$, $v_{\text{old}} = 0$, $\epsilon_V = 1$, $y = 3$.



Сплошная линия — полная потеря; стрелки — спуск по v . На $1 < v < 5$ градиент равен нулю.

Клиппинг не ограничивает само v . Слева и далеко справа градиент сохранён.

PPO: детали реализации имеют значение

Основа алгоритма

- Клиппированная цель актора.
- GAE и фиксированные цели критика.
- Несколько эпох по мини-батчам.
- Клиппинг критика — дополнительная опция.

При обновлении

- Нормировка преимуществ в мини-батче.
- Энтропийный бонус для исследования.
- В PPO-Clip явный KL-штраф не обязателен.

Масштаб данных

- Нормировка наблюдений и наград.
- При необходимости — ограничение их диапазона.
- Масштаб наград влияет на обучение критика и выбор ϵ_V .

Оптимизация сети

- Adam, уменьшение скорости обучения.
- Ограничение нормы градиента.
- Ортогональная инициализация, активации Tanh.
- Расписание ϵ — ещё одна опция.

Важно: цели критика вычисляем из исходных преимуществ, до их нормировки для актора.

PPO: сбор данных и расчёт GAE

Вход: θ, ϕ , число сред M , длина фрагмента H , параметры γ, λ

```
1:  $\theta_{\text{old}} \leftarrow \theta, \phi_{\text{old}} \leftarrow \phi$ 
2: Собираем  $M$  фрагментов по  $H$  переходов стратегией  $\pi_{\theta_{\text{old}}}$ 
3: Сохраняем  $(s_t, a_t, r_t, s_{t+1}, d_{t+1}, c_{t+1})$  для каждого перехода
4: Сохраняем  $\ell_t^{\text{old}} = \log \pi_{\theta_{\text{old}}}(a_t | s_t), v_t^{\text{old}} = V_{\phi_{\text{old}}}(s_t), v_{t+1}^+ = V_{\phi_{\text{old}}}(s_{t+1})$ 
5: for каждого фрагмента do
6:    $\hat{A}_H \leftarrow 0$ 
7:   for  $t = H - 1, H - 2, \dots, 0$  do
8:      $\delta_t \leftarrow r_t + \gamma(1 - d_{t+1})v_{t+1}^+ - v_t^{\text{old}}$ 
9:      $\hat{A}_t \leftarrow \delta_t + \gamma\lambda c_{t+1}\hat{A}_{t+1}$ 
10:     $y_t \leftarrow \hat{A}_t + v_t^{\text{old}}$ 
11:   end for
12: end for
13: Формируем  $\mathcal{D} = \{(s_t, a_t, \hat{A}_t, y_t, \ell_t^{\text{old}}, v_t^{\text{old}})\}$  из всех сред
14: return  $\mathcal{D}$ 
```

▷ фиксируем параметры

▷ граница фрагмента

▷ обратный проход GAE

▷ цель до нормировки преимуществ

▷ фиксирована на все эпохи обновления

$d = 1$ — терминальное состояние; $c = 1$ — следующий переход продолжает тот же эпизод. При внешнем лимите времени $d = 0, c = 0$: бутстрэп сохраняем, след GAE обрываем. Для v^+ берём последнее наблюдение до сброса среды.

PPO: обновление параметров

Вход: $\mathcal{D}$, K эпох, размер мини-батча B , ϵ, ϵ_V , шаги $\alpha_\theta, \alpha_\phi$, вес энтропии β

1: **for** $e = 1, \dots, K$ **do**

2: Перемешиваем $\mathcal{D}$ и разбиваем на мини-батчи $\mathcal{B}$ размера B

3: **for** каждого мини-батча $\mathcal{B}$ **do**

4: $\tilde{A}_i \leftarrow (\hat{A}_i - \text{mean}_{\mathcal{B}} \hat{A}) / (\text{std}_{\mathcal{B}} \hat{A} + 10^{-8})$

5: Вычисляем цель актора:

$$J_{\mathcal{B}} \leftarrow \frac{1}{|\mathcal{B}|} \sum_{i \in \mathcal{B}} \left[\min \left(\frac{\pi_\theta(a_i | s_i)}{\pi^{\text{old}}(a_i | s_i)} \tilde{A}_i, \text{clip} \left(\frac{\pi_\theta(a_i | s_i)}{\pi^{\text{old}}(a_i | s_i)}, 1 - \epsilon, 1 + \epsilon \right) \tilde{A}_i \right) + \beta \mathcal{H}(\pi_\theta(\cdot | s_i)) \right]$$

6: $v_i \leftarrow V_\phi(s_i)$, $\bar{v}_i \leftarrow v_i^{\text{old}} + \text{clip}(v_i - v_i^{\text{old}}, -\epsilon_V, \epsilon_V)$

7: $L_{\mathcal{B}} \leftarrow \frac{1}{|\mathcal{B}|} \sum_{i \in \mathcal{B}} \max((v_i - y_i)^2, (\bar{v}_i - y_i)^2)$

▷ критик

8: $g_\theta \leftarrow \nabla_\theta J_{\mathcal{B}}$, $g_\phi \leftarrow \nabla_\phi L_{\mathcal{B}}$; ограничиваем нормы градиентов

9: $\theta \leftarrow \theta + \alpha_\theta g_\theta$

▷ градиентный подъём для актора

10: $\phi \leftarrow \phi - \alpha_\phi g_\phi$

▷ градиентный спуск для критика

11: **end for**

12: **end for**

13: Отбрасываем $\mathcal{D}$ и возвращаемся к сбору данных новой стратегией

Где находится PPO среди методов RL?

Методы без модели среды, которые мы рассматриваем в курсе:

	Дискретные действия	Непрерывные действия
On-policy	PPO	PPO
Off-policy	DQN и расширения	TD3 / SAC

- PPO повторно использует **свежую выборку** несколько эпох, затем собирает новую.
- Off-policy методы используют буфер воспроизведения с данными от разных прошлых стратегий.
- Для непрерывных действий PPO задаёт распределение действий; DQN в базовом виде требует дискретного выбора.

Далее в курсе: непрерывное управление, TD3 и SAC.

04

Применения РРО

Применения PPO — кооперативный MARL

SMAC и SMACv2

Локальные наблюдения. Общая награда. Координация команды.

SMAC



2c_vs_64zg



3s_vs_5z



corridor

SMACv2



Терраны





Зерги



Протоссы




МиJoСо и многоагентное управление

В МаМиJoСо несколько агентов совместно управляют суставами одного тела.



IPPO и MAPPO

IPPO: локальный критик. MAPPO: централизованная информация для критика при обучении.



IPPO и MAPPO: сравнение результатов


Результаты кооперативных задач из исследования MAPPO.

Map	MAPPO _(FP)	MAPPO _(AS)	IPPO	QMix	RODE*	MAPPO* _(FP)	MAPPO* _(AS)
2m vs_1z	100.0 (0.0)	100.0 (0.0)	100.0 (0.0)	95.3 (5.2)	/	<u>100.0</u> (0.0)	<u>100.0</u> (0.0)
3m	100.0 (0.0)	100.0 (1.5)	100.0 (0.0)	96.9 (1.3)	/	<u>100.0</u> (0.0)	<u>100.0</u> (1.5)
2svs1sc	100.0 (0.0)	100.0 (0.0)	100.0 (1.5)	96.9 (2.9)	<u>100.0</u> (0.0)	<u>100.0</u> (0.0)	<u>100.0</u> (0.0)
2s3z	100.0 (0.7)	100.0 (1.5)	100.0 (0.0)	95.3 (2.5)	<u>100.0</u> (0.0)	<u>96.9</u> (1.5)	<u>96.9</u> (1.5)
3svs3z	100.0 (0.0)	100.0 (0.0)	100.0 (0.0)	96.9 (12.5)	/	<u>100.0</u> (0.0)	<u>100.0</u> (0.0)
3svs4z	100.0 (1.3)	98.4 (1.6)	99.2 (1.5)	97.7 (1.7)	/	<u>100.0</u> (2.1)	<u>100.0</u> (1.5)
so many baneling	100.0 (0.0)	100.0 (0.7)	100.0 (1.5)	96.9 (2.3)	/	<u>100.0</u> (1.5)	<u>96.9</u> (1.5)
8m	100.0 (0.0)	100.0 (0.0)	100.0 (0.7)	97.7 (1.9)	/	<u>100.0</u> (0.0)	<u>100.0</u> (0.0)
MMM	96.9 (0.6)	93.8 (1.5)	96.9 (0.0)	95.3 (2.5)	/	<u>93.8</u> (2.6)	<u>96.9</u> (1.5)
1c3s5z	100.0 (0.0)	96.9 (2.6)	100.0 (0.0)	96.1 (1.7)	<u>100.0</u> (0.0)	<u>100.0</u> (0.0)	<u>96.9</u> (2.6)
bane vs bane	100.0 (0.0)	100.0 (0.0)	100.0 (0.0)	100.0 (0.0)	<u>100.0</u> (46.4)	<u>100.0</u> (0.0)	<u>100.0</u> (0.0)
3svs5z	100.0 (0.6)	99.2 (1.4)	100.0 (0.0)	98.4 (2.4)	<u>78.9</u> (4.2)	<u>98.4</u> (5.5)	<u>100.0</u> (1.2)
2cvs64zg	100.0 (0.0)	100.0 (0.0)	98.4 (1.3)	92.2 (4.0)	<u>100.0</u> (0.0)	<u>96.9</u> (3.1)	<u>95.3</u> (3.5)
8mvs9m	96.9 (0.6)	96.9 (0.6)	96.9 (0.7)	92.2 (2.0)	/	<u>84.4</u> (5.1)	<u>87.5</u> (2.1)
25m	100.0 (1.5)	100.0 (4.0)	100.0 (0.0)	85.9 (7.1)	/	<u>96.9</u> (3.1)	<u>93.8</u> (2.9)
5mvs6m	89.1 (2.5)	88.3 (1.2)	87.5 (2.3)	75.8 (3.7)	<u>71.1</u> (9.2)	<u>65.6</u> (14.1)	<u>68.8</u> (8.2)
3s5z	96.9 (0.7)	96.9 (1.9)	96.9 (1.5)	88.3 (2.9)	<u>93.8</u> (2.0)	<u>71.9</u> (11.8)	<u>53.1</u> (15.4)
10mvs11m	96.9 (4.8)	96.9 (1.2)	93.0 (7.4)	95.3 (1.0)	<u>95.3</u> (2.2)	<u>81.2</u> (8.3)	<u>89.1</u> (5.5)
MMM2	90.6 (2.8)	87.5 (5.1)	86.7 (7.3)	87.5 (2.6)	<u>89.8</u> (6.7)	<u>51.6</u> (21.9)	<u>28.1</u> (29.6)
3s5zvs3s6z	84.4 (34.0)	63.3 (19.2)	82.8 (19.1)	82.8 (5.3)	<u>96.8</u> (25.11)	<u>75.0</u> (36.3)	<u>18.8</u> (37.4)
27mvs30m	93.8 (2.4)	85.9 (3.8)	69.5 (11.8)	39.1 (9.8)	<u>96.8</u> (1.5)	<u>93.8</u> (3.8)	<u>89.1</u> (6.5)
6hvs8z	88.3 (3.7)	85.9 (30.9)	84.4 (33.3)	9.4 (2.0)	<u>78.1</u> (37.0)	<u>78.1</u> (5.6)	<u>81.2</u> (31.8)
corridor	100.0 (1.2)	98.4 (0.8)	98.4 (3.1)	84.4 (2.5)	<u>65.6</u> (32.1)	<u>93.8</u> (3.5)	<u>93.8</u> (2.8)

Применения RPO — OpenAI Five


OpenAI Five: архитектура агента

Признаки наблюдений → память LSTM → оценка полезности и действия.




OpenAI Five: распределенное обучение

Параллельные процессы собирают траектории, вычисляют действия и обновляют параметры.



OpenAI Five: результаты


Уровень игры TrueSkill растет с вычислительными затратами на обучение.



Sample Factory


Sample Factory: асинхронный сбор опыта

Среды на CPU, исполнители стратегии на GPU и обучающий процесс работают параллельно.




Sample Factory: двойная буферизация

Две группы сред позволяют перекрывать вычисления на CPU и GPU.



Sample Factory: скорость сбора опыта


Сравнение пропускной способности на Atari, VizDoom и DMLab: кадры в секунду (FPS).



Дообучение моделей — VPT

VPT: учимся действовать по видеозаписям

Размеченные действия → обратная модель динамики → разметка интернет-видео → стратегия.



VPT: ошибка предобучения

Предобучаем стратегию имитацией действий из видеозаписей.

Standard BC (negative log-likelihood):

$$\min_{\theta} \sum_{t \in [1 \dots T]} -\log \pi_{\theta}(a_t | o_1, \dots, o_t), \text{ where } a_t \sim p_{\text{IDM}}(a_t | o_1, \dots, o_t, \dots, o_T)$$



VPT: навыки после предобучения

Имитация видео формирует базовые навыки добычи ресурсов и создания предметов.



PPG: фаза стратегии

θ — актер, ϕ — критик; $y_i = \hat{A}_i + V^{\text{old}}(s_i)$.

```
1:  $B \leftarrow \emptyset$  ▷ начало нового цикла PPG
2: for  $k = 1, \dots, N_\pi$  do
3:   Собрать данные  $\mathcal{D}$ ; вычислить преимущества  $\hat{A}_i$  и цели  $y_i$  с помощью GAE
4:   Сохранить  $\pi_{\text{old}}(a_i \mid s_i)$  для всех переходов в  $\mathcal{D}$ 
5:   for  $e = 1, \dots, E_\pi$  do ▷ эпохи актора на текущих данных  $\mathcal{D}$ 
6:     Вычислить потерю актора:

$$L_\pi(\theta) = -\frac{1}{|\mathcal{D}|} \sum_{i \in \mathcal{D}} \left[ \min \left( \frac{\pi_\theta(a_i \mid s_i)}{\pi_{\text{old}}(a_i \mid s_i)} \hat{A}_i, \text{clip} \left( \frac{\pi_\theta(a_i \mid s_i)}{\pi_{\text{old}}(a_i \mid s_i)}, 1 - \epsilon, 1 + \epsilon \right) \hat{A}_i \right) + \beta_S \mathcal{H}(\pi_\theta(\cdot \mid s_i)) \right]$$

7:      $\theta \leftarrow \theta - \alpha_\pi \nabla_\theta L_\pi$  ▷ эквивалентно подъёму по цели PPO
8:   end for
9:   for  $e = 1, \dots, E_V$  do ▷ эпохи критика на текущих данных  $\mathcal{D}$ 
10:     $L_V(\phi) = \frac{1}{2|\mathcal{D}|} \sum_{i \in \mathcal{D}} (V_\phi(s_i) - y_i)^2$ 
11:     $\phi \leftarrow \phi - \alpha_V \nabla_\phi L_V$ 
12:   end for
13:   Добавить все пары  $(s_i, y_i)$  из  $\mathcal{D}$  в  $B$ 
14: end for
```

PRG: вспомогательная фаза

V_θ^{aux} — дополнительная голова актора; V_ϕ — отдельный критик.

1: Сохранить $\pi_{\text{ref}}(\cdot \mid s_i) \leftarrow \pi_\theta(\cdot \mid s_i)$ для всех состояний в B

2: **for** $e = 1, \dots, E_{\text{aux}}$ **do**

▷ эпохи на всём накопленном буфере B

3: Вычислить потерю актора с дополнительной головой полезности:

$$L_{\text{aux}}(\theta) = \frac{1}{2|B|} \sum_{i \in B} (V_\theta^{\text{aux}}(s_i) - y_i)^2 + \frac{\beta_{\text{clone}}}{|B|} \sum_{i \in B} D_{\text{KL}}(\pi_{\text{ref}}(\cdot \mid s_i) \parallel \pi_\theta(\cdot \mid s_i))$$

4: $\theta \leftarrow \theta - \alpha_{\text{aux}} \nabla_\theta L_{\text{aux}}$

5: Вычислить потерю отдельного критика:

$$L_V(\phi) = \frac{1}{2|B|} \sum_{i \in B} (V_\phi(s_i) - y_i)^2$$

6: $\phi \leftarrow \phi - \alpha_V \nabla_\phi L_V$

7: **end for**

8: Вернуться к фазе стратегии и начать новый цикл с пустым буфером

VPT: как сохранить навыки при дообучении

Предобученная стратегия π_{pt} задает ориентир на протяжении дообучения.

$$\max_{\theta} \mathcal{L}^{\text{CLIP}}(\theta) - \rho \mathbb{E}_s D_{\text{KL}}(\pi_{\text{pt}} \parallel \pi_{\theta}).$$

- π_{pt} заморожена.
- ρ регулирует сохранение исходного поведения.
- π_{old} в цели PPO обновляется между циклами сбора опыта; это другой ориентир.




VPT: награда при дообучении

Предобученная стратегия помогает быстрее начать получать награду.




VPT: дообучение базовой модели

Доля эпизодов с получением предметов при RL-дообучении базовой модели VPT.



VPT: дообучение модели ранней игры

Старт с модели ранней игры: алмазная кирка появляется в 2.5% эпизодов.



Вопросы?