

Непрерывное пространство действий

Алексей Скрынник

ПЛАН

01 Мотивация

02 DDPG

03 Twin Delayed DDPG

04 Soft Actor-Critic

01



Мотивация

Зачем непрерывное пространство действий?


Задача: удерживать маятник вертикально, управляя моментом двигателя.

Состояние маятника: $s_t = (\alpha_t, \omega_t)$.

α_t — угол; $\omega_t = \dot{\alpha}_t$ — угловая скорость.

$$a_t \in [-u_{\max}, u_{\max}] \subset \mathbb{R}$$

Вопрос: какой момент приложить сейчас — 0.2, 0.23, 0.237?



Зачем непрерывное пространство действий?

Задача: удерживать маятник вертикально, управляя моментом двигателя.

Состояние маятника: $s_t = (\alpha_t, \omega_t)$.


α_t — угол; $\omega_t = \dot{\alpha}_t$ — угловая скорость.

$$a_t \in [-u_{\max}, u_{\max}] \subset \mathbb{R}$$

Вопрос: какой момент приложить сейчас — 0.2, 0.23, 0.237?

Почему не разбить действия на сетку?

- Грубая сетка ограничивает точность; мелкая увеличивает число вариантов.
- k уровней по каждой из m координат $\Rightarrow k^m$ комбинаций.
- Робот с 7 суставами и 10 уровнями момента на сустав: 10^7 действий.



Зачем непрерывное пространство действий?

Задача: удерживать маятник вертикально, управляя моментом двигателя.

Состояние маятника: $s_t = (\alpha_t, \omega_t)$.

α_t — угол; $\omega_t = \dot{\alpha}_t$ — угловая скорость.


$$a_t \in [-u_{\max}, u_{\max}] \subset \mathbb{R}$$

Вопрос: какой момент приложить сейчас — 0.2, 0.23, 0.237?

Почему не разбить действия на сетку?

- Грубая сетка ограничивает точность; мелкая увеличивает число вариантов.
- k уровней по каждой из m координат $\Rightarrow k^m$ комбинаций.
- Робот с 7 суставами и 10 уровнями момента на сустав: 10^7 действий.

Цель лекции: научиться выдавать вектор действий напрямую.



MDP с непрерывным пространством действий

Та же модель принятия решений:

$$\mathcal{M} = (\mathcal{S}, \mathcal{A}, P, r, \rho_0, \gamma), \quad \mathcal{A} \subseteq \mathbb{R}^m.$$

- $s_t \in \mathcal{S}$ — состояние; $a_t \in \mathcal{A}$ — вектор управления.
- $s_0 \sim \rho_0$, $s_{t+1} \sim P(\cdot \mid s_t, a_t)$ — начальное состояние и переход.
- $r(s_t, a_t)$ — ожидаемая награда; $0 \leq \gamma < 1$ — дисконтирование.

Марковское свойство: распределение следующего состояния зависит от истории только через (s_t, a_t) .

MDP с непрерывным пространством действий

Та же модель принятия решений:

$$\mathcal{M} = (\mathcal{S}, \mathcal{A}, P, r, \rho_0, \gamma), \quad \mathcal{A} \subseteq \mathbb{R}^m.$$

- $s_t \in \mathcal{S}$ — состояние; $a_t \in \mathcal{A}$ — вектор управления.
- $s_0 \sim \rho_0$, $s_{t+1} \sim P(\cdot \mid s_t, a_t)$ — начальное состояние и переход.
- $r(s_t, a_t)$ — ожидаемая награда; $0 \leq \gamma < 1$ — дисконтирование.

Марковское свойство: распределение следующего состояния зависит от истории только через (s_t, a_t) .

Цель остаётся прежней:

$$\max_{\pi} J(\pi), \quad J(\pi) = \mathbb{E}_{\rho_0, P, \pi} \left[\sum_{t=0}^{\infty} \gamma^t r(s_t, a_t) \right].$$

Непрерывны действия, а не время: $t = 0, 1, 2, \dots$; пространство состояний может быть дискретным или непрерывным.

Как задаётся стратегия?

Стохастическая стратегия

$$a_t \sim \pi_\theta(\cdot \mid s_t)$$

Если есть плотность $\pi_\theta(a \mid s)$, то

$$\Pr(a_t \in B \mid s_t = s) = \int_B \pi_\theta(a \mid s) da.$$

Плотность — не вероятность одной точки: для такой стратегии $\Pr(a_t = a \mid s_t = s) = 0$.

Как задаётся стратегия?

Стохастическая стратегия

$$a_t \sim \pi_\theta(\cdot \mid s_t)$$

Если есть плотность $\pi_\theta(a \mid s)$, то

$$\Pr(a_t \in B \mid s_t = s) = \int_B \pi_\theta(a \mid s) da.$$

Плотность — не вероятность одной точки: для такой стратегии $\Pr(a_t = a \mid s_t = s) = 0$.

Детерминированная стратегия

$$a_t = \mu_\theta(s_t) \in \mathcal{A}$$

Одному состоянию соответствует одно действие.

Для маятника можно обеспечить границы:

$$\mu_\theta(s) = u_{\max} \tanh f_\theta(s).$$

Даже при заданных s_t и a_t следующее состояние может быть случайным.

Как задаётся стратегия?

Стохастическая стратегия

$$a_t \sim \pi_\theta(\cdot \mid s_t)$$

Если есть плотность $\pi_\theta(a \mid s)$, то

$$\Pr(a_t \in B \mid s_t = s) = \int_B \pi_\theta(a \mid s) da.$$

Плотность — не вероятность одной точки: для такой стратегии $\Pr(a_t = a \mid s_t = s) = 0$.

Связь с прошлыми лекциями: VPG, A2C и PPO тоже работают с непрерывными действиями, если выбрать подходящее распределение стратегии.

Детерминированная стратегия

$$a_t = \mu_\theta(s_t) \in \mathcal{A}$$

Одному состоянию соответствует одно действие.

Для маятника можно обеспечить границы:

$$\mu_\theta(s) = u_{\max} \tanh f_\theta(s).$$

Даже при заданных s_t и a_t следующее состояние может быть случайным.

Что меняется в уравнениях Беллмана?

$Q^\pi(s, a)$ — ожидаемая дисконтированная отдача: сначала действие a , затем стратегия π .

$$Q^\pi(s, a) = r(s, a) + \gamma \mathbb{E}_{s' \sim P(\cdot | s, a)}[V^\pi(s')].$$

Что меняется в уравнениях Беллмана?

$Q^\pi(s, a)$ — ожидаемая дисконтированная отдача: сначала действие a , затем стратегия π .

$$Q^\pi(s, a) = r(s, a) + \gamma \mathbb{E}_{s' \sim P(\cdot | s, a)}[V^\pi(s')].$$

Для стратегии с плотностью сумма по действиям становится интегралом:

$$\underbrace{\sum_{a \in \mathcal{A}} \pi(a | s) Q^\pi(s, a)}_{\text{дискретные действия}} \longrightarrow V^\pi(s) = \underbrace{\int_{\mathcal{A}} \pi(a | s) Q^\pi(s, a) da}_{\text{непрерывные действия}}.$$

Для детерминированной стратегии: $V^\mu(s) = Q^\mu(s, \mu(s))$.

Что меняется в уравнениях Беллмана?

$Q^\pi(s, a)$ — ожидаемая дисконтированная отдача: сначала действие a , затем стратегия π .

$$Q^\pi(s, a) = r(s, a) + \gamma \mathbb{E}_{s' \sim P(\cdot | s, a)}[V^\pi(s')].$$

Для стратегии с плотностью сумма по действиям становится интегралом:

$$\underbrace{\sum_{a \in \mathcal{A}} \pi(a | s) Q^\pi(s, a)}_{\text{дискретные действия}} \longrightarrow V^\pi(s) = \underbrace{\int_{\mathcal{A}} \pi(a | s) Q^\pi(s, a) da}_{\text{непрерывные действия}}.$$

Для детерминированной стратегии: $V^\mu(s) = Q^\mu(s, \mu(s))$.

Оптимальность Беллмана (если максимум достигается):

$$Q^*(s, a) = r(s, a) + \gamma \mathbb{E}_{s' \sim P(\cdot | s, a)} \left[\max_{a' \in \mathcal{A}} Q^*(s', a') \right].$$

Новая трудность: как найти максимум по непрерывному вектору a' ?

Проблема $\arg\max$ в непрерывных пространствах

Дискретные действия (DQN):

- $a^* = \arg \max_{a \in \mathcal{A}} Q_\phi(s, a)$
- При небольшом $|\mathcal{A}|$ можно перебрать все действия

Проблема $\arg\max$ в непрерывных пространствах

Дискретные действия (DQN):

- $a^* = \arg \max_{a \in \mathcal{A}} Q_\phi(s, a)$
- При небольшом $|\mathcal{A}|$ можно перебрать все действия

Непрерывные действия:

- Нельзя перебрать все $a \in \mathcal{A} \subseteq \mathbb{R}^m$
- $\max_a Q_\phi(s, a)$ требует отдельной оптимизации

Проблема $\arg\max$ в непрерывных пространствах

Дискретные действия (DQN):

- $a^* = \arg \max_{a \in \mathcal{A}} Q_\phi(s, a)$
- При небольшом $|\mathcal{A}|$ можно перебрать все действия

Непрерывные действия:

- Нельзя перебрать все $a \in \mathcal{A} \subseteq \mathbb{R}^m$
- $\max_a Q_\phi(s, a)$ требует отдельной оптимизации

Два подхода:

1. **Детерминированный актер:** учится выдавать действие с высоким $Q_\phi(s, a)$ (DDPG, TD3)
2. **Стохастический актер:** повышает ожидаемый Q и сохраняет энтропию (SAC)

Критик принимает пару (s, a) и выдаёт число: $Q_\phi(s, a) \in \mathbb{R}$.


От on-policy к off-policy актор-критик

- Непрерывные действия не требуют off-policy обучения: это **отдельный выбор**.
- Сегодня — **off-policy актор-критик**: переиспользуем переходы от предыдущих стратегий через replay buffer, чтобы экономить взаимодействия со средой.

От on-policy к off-policy актер-критик

- Непрерывные действия не требуют off-policy обучения: это **отдельный выбор**.
- Сегодня — **off-policy актер-критик**: переиспользуем переходы от предыдущих стратегий через replay buffer, чтобы экономить взаимодействия со средой.

Наш план: DDPG (базовая идея) → TD3 (стабилизация) → SAC (энтропия)



От argmax к детерминированной стратегии

Что мы хотим в идеале?

$$a^*(s) = \arg \max_{a \in \mathcal{A}} Q_\phi(s, a)$$

От argmax к детерминированной стратегии

Что мы хотим в идеале?

$$a^*(s) = \arg \max_{a \in \mathcal{A}} Q_\phi(s, a)$$

Проблема: заново искать максимум для каждого состояния **дорого и неудобно**

От argmax к детерминированной стратегии

Что мы хотим в идеале?

$$a^*(s) = \arg \max_{a \in \mathcal{A}} Q_{\phi}(s, a)$$

Проблема: заново искать максимум для каждого состояния **дорого и неудобно**

Идея: заменить внутреннюю оптимизацию обучаемой функцией

$$\mu_{\theta}(s) \approx a^*(s)$$

От $\arg\max$ к детерминированной стратегии

Что мы хотим в идеале?

$$a^*(s) = \arg \max_{a \in \mathcal{A}} Q_\phi(s, a)$$

Проблема: заново искать максимум для каждого состояния **дорого и неудобно**

Идея: заменить внутреннюю оптимизацию обучаемой функцией

$$\mu_\theta(s) \approx a^*(s)$$

Практическая цель актора при фиксированном критике:

$$\max_{\theta} \mathbb{E}_{s \sim \mathcal{D}} [Q_\phi(s, \mu_\theta(s))]$$

От $\arg\max$ к детерминированной стратегии

Что мы хотим в идеале?

$$a^*(s) = \arg \max_{a \in \mathcal{A}} Q_\phi(s, a)$$

Проблема: заново искать максимум для каждого состояния **дорого и неудобно**

Идея: заменить внутреннюю оптимизацию обучаемой функцией

$$\mu_\theta(s) \approx a^*(s)$$

Практическая цель актора при фиксированном критике:

$$\max_{\theta} \mathbb{E}_{s \sim \mathcal{D}} [Q_\phi(s, \mu_\theta(s))]$$

$\mathcal{D}$ — replay buffer. Если Q_ϕ и μ_θ дифференцируемы, можно:

- понять, **в какую сторону по действию** растёт Q
- передать этот сигнал через $\mu_\theta(s)$ к параметрам θ

Теорема DPG: от вероятностей к действиям

Стохастическая стратегия: $a \sim \pi_\theta(\cdot \mid s)$.

$$\nabla_\theta J(\pi_\theta) = \frac{1}{1 - \gamma} \mathbb{E}_{s \sim d^\pi, a \sim \pi_\theta} [\nabla_\theta \log \pi_\theta(a \mid s) Q^\pi(s, a)] .$$

Идея: повышаем вероятность действий с более высоким Q .

Теорема DPG: от вероятностей к действиям

Стохастическая стратегия: $a \sim \pi_\theta(\cdot \mid s)$.

$$\nabla_\theta J(\pi_\theta) = \frac{1}{1 - \gamma} \mathbb{E}_{s \sim d^\pi, a \sim \pi_\theta} [\nabla_\theta \log \pi_\theta(a \mid s) Q^\pi(s, a)] .$$

Идея: повышаем вероятность действий с более высоким Q .

Детерминированная стратегия: $a = \mu_\theta(s)$.

$$\nabla_\theta J(\mu_\theta) = \frac{1}{1 - \gamma} \mathbb{E}_{s \sim d^\mu} \left[D_\theta \mu_\theta(s)^\top \nabla_a Q^\mu(s, a) \Big|_{a=\mu_\theta(s)} \right] .$$

Идея: сдвигаем само действие в сторону большего Q .

Теорема DPG: от вероятностей к действиям

Стохастическая стратегия: $a \sim \pi_\theta(\cdot \mid s)$.

$$\nabla_\theta J(\pi_\theta) = \frac{1}{1 - \gamma} \mathbb{E}_{s \sim d^\pi, a \sim \pi_\theta} [\nabla_\theta \log \pi_\theta(a \mid s) Q^\pi(s, a)].$$

Идея: повышаем вероятность действий с более высоким Q .

Детерминированная стратегия: $a = \mu_\theta(s)$.

$$\nabla_\theta J(\mu_\theta) = \frac{1}{1 - \gamma} \mathbb{E}_{s \sim d^\mu} \left[D_\theta \mu_\theta(s)^\top \nabla_a Q^\mu(s, a) \Big|_{a=\mu_\theta(s)} \right].$$

Идея: сдвигаем само действие в сторону большего Q .


Для непрерывного действия критик может подсказать не только **«насколько хорошо»**, но и **«в какую сторону изменить»**.

d^π — нормированное распределение посещений с дисконтированием; для DPG нужны условия гладкости и регулярности.

Интуиция: обучаем замену $\arg\max$

1. Есть критик $Q_\phi(s, a)$. Можем оценить полезность заданного действия.

Один шаг обучения при заданном s



Интуиция: обучаем замену $\arg\max$


1. Есть критик $Q_\phi(s, a)$. Можем оценить полезность заданного действия.

2. Хотим лучшее действие:

$$a^*(s) = \arg \max_{a \in \mathcal{A}} Q_\phi(s, a).$$

Для каждого нового состояния нужен новый поиск:
много вычислений Q .

Один шаг обучения при заданном s



Интуиция: обучаем замену $\arg\max$

1. Есть критик $Q_\phi(s, a)$. Можем оценить полезность заданного действия.

2. Хотим лучшее действие:

$$a^*(s) = \arg \max_{a \in \mathcal{A}} Q_\phi(s, a).$$


Для каждого нового состояния нужен новый поиск:
много вычислений Q .

3. Обучаем актора $a = \mu_\theta(s)$. Градиент критика подсказывает, как обновить **параметры θ** .

Выбор действия — **один проход через актора**.

При обучении: критик фиксирован, обновляем актора.

Один шаг обучения при заданном s



02



DDPG

Deep Deterministic Policy Gradient

Критик: почти как в DQN

$$y_{\text{DQN}} = r + \gamma(1 - d) \max_{a'} Q_{\phi_{\text{targ}}}(s', a')$$

$$y_{\text{DDPG}} = r + \gamma(1 - d) Q_{\phi_{\text{targ}}}(s', \mu_{\theta_{\text{targ}}}(s'))$$

$$L(\phi) = \mathbb{E}_{(s,a,r,s',d) \sim \mathcal{D}} \left[\left(Q_{\phi}(s, a) - y_{\text{DDPG}} \right)^2 \right]$$

Deep Deterministic Policy Gradient

Критик: почти как в DQN

$$y_{\text{DQN}} = r + \gamma(1 - d) \max_{a'} Q_{\phi_{\text{targ}}}(s', a')$$

$$y_{\text{DDPG}} = r + \gamma(1 - d) Q_{\phi_{\text{targ}}}(s', \mu_{\theta_{\text{targ}}}(s'))$$

$$L(\phi) = \mathbb{E}_{(s,a,r,s',d) \sim \mathcal{D}} \left[\left(Q_{\phi}(s, a) - y_{\text{DDPG}} \right)^2 \right]$$

Ключевая замена: вместо $\max_{a'}$ используем
target actor $\mu_{\theta_{\text{targ}}}(s')$

Deep Deterministic Policy Gradient

Критик: почти как в DQN

$$y_{\text{DQN}} = r + \gamma(1 - d) \max_{a'} Q_{\phi_{\text{targ}}}(s', a')$$

$$y_{\text{DDPG}} = r + \gamma(1 - d) Q_{\phi_{\text{targ}}}(s', \mu_{\theta_{\text{targ}}}(s'))$$


$$L(\phi) = \mathbb{E}_{(s,a,r,s',d) \sim \mathcal{D}} \left[\left(Q_{\phi}(s, a) - y_{\text{DDPG}} \right)^2 \right]$$

Ключевая замена: вместо $\max_{a'}$ используем **target actor** $\mu_{\theta_{\text{targ}}}(s')$

Актор — максимизация Q-функции (из теоремы DPG):

$$\max_{\theta} \mathbb{E}_{s \sim \mathcal{D}} [Q_{\phi}(s, \mu_{\theta}(s))]$$

Параметры ϕ рассматриваются как **константы** при обновлении стратегии



Стабилизация обучения в DDPG

Replay buffer и target сети — как в DQN (Лекция 4).

Практическое отличие DDPG: target сети обновляем **мягко**, а не жёстким копированием

Стабилизация обучения в DDPG

Replay buffer и target сети — как в DQN (Лекция 4).

Практическое отличие DDPG: target сети обновляем **мягко**, а не жёстким копированием

DQN: периодически копируем параметры целевой сети

Стабилизация обучения в DDPG

Replay buffer и target сети — как в DQN (Лекция 4).

Практическое отличие DDPG: target сети обновляем **мягко**, а не жёстким копированием

DQN: периодически копируем параметры целевой сети

DDPG: усреднение Поляка (Polyak averaging)

$$\phi_{\text{targ}} \leftarrow \rho \phi_{\text{targ}} + (1 - \rho) \phi \quad \theta_{\text{targ}} \leftarrow \rho \theta_{\text{targ}} + (1 - \rho) \theta$$

где $\rho \approx 0.995$

Стабилизация обучения в DDPG

Replay buffer и target сети — как в DQN (Лекция 4).

Практическое отличие DDPG: target сети обновляем **мягко**, а не жёстким копированием

DQN: периодически копируем параметры целевой сети

DDPG: усреднение Поляка (Polyak averaging)

$$\phi_{\text{targ}} \leftarrow \rho \phi_{\text{targ}} + (1 - \rho) \phi \quad \theta_{\text{targ}} \leftarrow \rho \theta_{\text{targ}} + (1 - \rho) \theta$$

где $\rho \approx 0.995$

Это делает цели **более плавными** и снижает нестабильность обучения

Исследование в DDPG

- Детерминированная стратегия — **нет встроенного исследования**
- Добавляем **шум** к действиям:

$$a = \text{clip}(\mu_{\theta}(s) + \epsilon, a_{\text{low}}, a_{\text{high}}), \quad \epsilon \sim \mathcal{N}(0, \sigma)$$

Исследование в DDPG

- Детерминированная стратегия — **нет встроенного исследования**

- Добавляем **шум** к действиям:

$$a = \text{clip}(\mu_{\theta}(s) + \epsilon, a_{\text{low}}, a_{\text{high}}), \quad \epsilon \sim \mathcal{N}(0, \sigma)$$

- Оригинальная статья предлагала шум Орнштейна-Уленбека, но **некоррелированный гауссовский шум** работает не хуже и проще
- Масштаб шума можно **уменьшать со временем** (опционально)

Псевдокод DDPG

Вход: параметры стратегии θ , Q-функции ϕ , пустой буфер $\mathcal{D}$

1: $\theta_{\text{targ}} \leftarrow \theta, \phi_{\text{targ}} \leftarrow \phi$

2: **repeat**

14: **until** СХОДИМОСТЬ

Псевдокод DDPG

Вход: параметры стратегии θ , Q-функции ϕ , пустой буфер $\mathcal{D}$

1: $\theta_{\text{targ}} \leftarrow \theta, \phi_{\text{targ}} \leftarrow \phi$

2: **repeat**

3: Получаем s , выбираем $a = \text{clip}(\mu_{\theta}(s) + \epsilon, a_{\text{low}}, a_{\text{high}}), \epsilon \sim \mathcal{N}$

4: Выполняем a , получаем s', r, d ; сохраняем (s, a, r, s', d) в $\mathcal{D}$

14: **until** СХОДИМОСТЬ

Псевдокод DDPG

Вход: параметры стратегии θ , Q-функции ϕ , пустой буфер $\mathcal{D}$

```
1:  $\theta_{\text{targ}} \leftarrow \theta, \phi_{\text{targ}} \leftarrow \phi$ 
2: repeat
3:   Получаем  $s$ , выбираем  $a = \text{clip}(\mu_{\theta}(s) + \epsilon, a_{\text{low}}, a_{\text{high}}), \epsilon \sim \mathcal{N}$ 
4:   Выполняем  $a$ , получаем  $s', r, d$ ; сохраняем  $(s, a, r, s', d)$  в  $\mathcal{D}$ 
5:   if пора обновлять then
6:     for число обновлений do
7:       Батч  $B = \{(s, a, r, s', d)\}$  из  $\mathcal{D}$ 
8:       Обновить  $\theta$  и  $\phi$  с помощью батча  $B$ 
9:     end for
10:   end if
11: until сходимость
```

Псевдокод DDPG

Вход: параметры стратегии θ , Q-функции ϕ , пустой буфер $\mathcal{D}$

```
1:  $\theta_{\text{targ}} \leftarrow \theta, \phi_{\text{targ}} \leftarrow \phi$ 
2: repeat
3:   Получаем  $s$ , выбираем  $a = \text{clip}(\mu_{\theta}(s) + \epsilon, a_{\text{low}}, a_{\text{high}}), \epsilon \sim \mathcal{N}$ 
4:   Выполняем  $a$ , получаем  $s', r, d$ ; сохраняем  $(s, a, r, s', d)$  в  $\mathcal{D}$ 
5:   if пора обновлять then
6:     for число обновлений do
7:       Батч  $B = \{(s, a, r, s', d)\}$  из  $\mathcal{D}$ 
8:        $y = r + \gamma(1 - d) Q_{\phi_{\text{targ}}}(s', \mu_{\theta_{\text{targ}}}(s'))$ 
9:        $\nabla_{\phi} \frac{1}{|B|} \sum (Q_{\phi}(s, a) - y)^2$ 
12:    end for
13:  end if
14: until СХОДИМОСТЬ
```

▷ цели

▷ критик

Псевдокод DDPG

Вход: параметры стратегии θ , Q-функции ϕ , пустой буфер $\mathcal{D}$

```
1:  $\theta_{\text{targ}} \leftarrow \theta, \phi_{\text{targ}} \leftarrow \phi$ 
2: repeat
3:   Получаем  $s$ , выбираем  $a = \text{clip}(\mu_{\theta}(s) + \epsilon, a_{\text{low}}, a_{\text{high}}), \epsilon \sim \mathcal{N}$ 
4:   Выполняем  $a$ , получаем  $s', r, d$ ; сохраняем  $(s, a, r, s', d)$  в  $\mathcal{D}$ 
5:   if пора обновлять then
6:     for число обновлений do
7:       Батч  $B = \{(s, a, r, s', d)\}$  из  $\mathcal{D}$ 
8:        $y = r + \gamma(1 - d) Q_{\phi_{\text{targ}}}(s', \mu_{\theta_{\text{targ}}}(s'))$ 
9:        $\nabla_{\phi} \frac{1}{|B|} \sum (Q_{\phi}(s, a) - y)^2$ 
10:       $\nabla_{\theta} \frac{1}{|B|} \sum Q_{\phi}(s, \mu_{\theta}(s))$ 
12:     end for
13:   end if
14: until сходимость
```

▷ цели
▷ критик
▷ актор

Псевдокод DDPG

Вход: параметры стратегии θ , Q-функции ϕ , пустой буфер $\mathcal{D}$

```
1:  $\theta_{\text{targ}} \leftarrow \theta, \phi_{\text{targ}} \leftarrow \phi$ 
2: repeat
3:   Получаем  $s$ , выбираем  $a = \text{clip}(\mu_{\theta}(s) + \epsilon, a_{\text{low}}, a_{\text{high}}), \epsilon \sim \mathcal{N}$ 
4:   Выполняем  $a$ , получаем  $s', r, d$ ; сохраняем  $(s, a, r, s', d)$  в  $\mathcal{D}$ 
5:   if пора обновлять then
6:     for число обновлений do
7:       Батч  $B = \{(s, a, r, s', d)\}$  из  $\mathcal{D}$ 
8:        $y = r + \gamma(1 - d) Q_{\phi_{\text{targ}}}(s', \mu_{\theta_{\text{targ}}}(s'))$ 
9:        $\nabla_{\phi} \frac{1}{|B|} \sum (Q_{\phi}(s, a) - y)^2$ 
10:       $\nabla_{\theta} \frac{1}{|B|} \sum Q_{\phi}(s, \mu_{\theta}(s))$ 
11:       $\phi_{\text{targ}} \leftarrow \rho \phi_{\text{targ}} + (1 - \rho) \phi; \theta_{\text{targ}} \leftarrow \rho \theta_{\text{targ}} + (1 - \rho) \theta$ 
12:     end for
13:   end if
14: until СХОДИМОСТЬ
```

▷ цели

▷ критик

▷ актер

▷ Polyak

03

Twin Delayed DDPG

Ограничения DDPG и три методики TD3

- DDPG **неустойчив** к гиперпараметрам; ключевая проблема — **завышение оценок Q-функции, т.е. переоценка полезностей**

Ограничения DDPG и три методики TD3

- DDPG **неустойчив** к гиперпараметрам; ключевая проблема — **завышение оценок Q-функции, т.е. переоценка полезностей**

Twin Delayed DDPG (TD3) решает это тремя методиками:

Ограничения DDPG и три методики TD3

- DDPG **неустойчив** к гиперпараметрам; ключевая проблема — **завышение оценок Q-функции, т.е. переоценка полезностей**

Twin Delayed DDPG (TD3) решает это тремя методиками:

1. **Clipped Double-Q Learning**: обучаем **две** Q-функции, используем **минимум** для целей — уменьшает смещение завышения

Ограничения DDPG и три методики TD3

- DDPG **неустойчив** к гиперпараметрам; ключевая проблема — **завышение оценок Q-функции, т.е. переоценка полезностей**

Twin Delayed DDPG (TD3) решает это тремя методиками:

1. **Clipped Double-Q Learning:** обучаем **две** Q-функции, используем **минимум** для целей — уменьшает смещение завышения
2. **Delayed Policy Updates:** обновляем стратегию **реже** Q-функции (1:2) — снижает нестабильность

Ограничения DDPG и три методики TD3

- DDPG **неустойчив** к гиперпараметрам; ключевая проблема — **завышение оценок Q-функции, т.е. переоценка полезностей**

Twin Delayed DDPG (TD3) решает это тремя методиками:

1. **Clipped Double-Q Learning:** обучаем **две** Q-функции, используем **минимум** для целей — уменьшает смещение завышения
2. **Delayed Policy Updates:** обновляем стратегию **реже** Q-функции (1:2) — снижает нестабильность
3. **Target Policy Smoothing:** добавляем шум к целевому действию — сглаживает пики Q-функции

Ключевые уравнения TD3

1. **Clipped Double-Q**: в цели берём **минимум** двух target Q-сетей

Ключевые уравнения TD3

1. **Clipped Double-Q:** в цели берём **минимум** двух target Q-сетей
2. **Delayed Policy Updates:** стратегию обновляем реже критика (подробно на следующем слайде)

Ключевые уравнения TD3

1. **Clipped Double-Q:** в цели берём **минимум** двух target Q-сетей
2. **Delayed Policy Updates:** стратегию обновляем реже критика (подробно на следующем слайде)
3. **Target Policy Smoothing:**

$$a'(s') = \text{clip} \left(\mu_{\theta_{\text{targ}}}(s') + \text{clip}(\tilde{\epsilon}, -c, c), a_{\text{low}}, a_{\text{high}} \right), \quad \tilde{\epsilon} \sim \mathcal{N}(0, \sigma)$$

Ключевые уравнения TD3

1. **Clipped Double-Q:** в цели берём **минимум** двух target Q-сетей
2. **Delayed Policy Updates:** стратегию обновляем реже критика (подробно на следующем слайде)
3. **Target Policy Smoothing:**

$$a'(s') = \text{clip} \left(\mu_{\theta_{\text{targ}}}(s') + \text{clip}(\tilde{\epsilon}, -c, c), a_{\text{low}}, a_{\text{high}} \right), \quad \tilde{\epsilon} \sim \mathcal{N}(0, \sigma)$$

Итоговая цель критика:

$$y(r, s', d) = r + \gamma(1 - d) \min_{i=1,2} Q_{\phi_i, \text{targ}}(s', a'(s'))$$

Ключевые уравнения TD3

1. **Clipped Double-Q:** в цели берём **минимум** двух target Q-сетей
2. **Delayed Policy Updates:** стратегию обновляем реже критика (подробно на следующем слайде)
3. **Target Policy Smoothing:**

$$a'(s') = \text{clip} \left(\mu_{\theta_{\text{targ}}}(s') + \text{clip}(\tilde{\epsilon}, -c, c), a_{\text{low}}, a_{\text{high}} \right), \quad \tilde{\epsilon} \sim \mathcal{N}(0, \sigma)$$

Итоговая цель критика:

$$y(r, s', d) = r + \gamma(1 - d) \min_{i=1,2} Q_{\phi_i, \text{targ}}(s', a'(s'))$$

Функции потерь для каждой Q-сети ($i = 1, 2$):

$$L(\phi_i, \mathcal{D}) = \mathbb{E}_{(s,a,r,s',d) \sim \mathcal{D}} \left[(Q_{\phi_i}(s, a) - y(r, s', d))^2 \right]$$

Обучение стратегии в TD3

2. Delayed Policy Updates

- Стратегия обучается путём **максимизации Q-функции** (как в DDPG):

$$\max_{\theta} \mathbb{E}_{s \sim \mathcal{D}} [Q_{\phi_1}(s, \mu_{\theta}(s))]$$

Обучение стратегии в TD3

2. Delayed Policy Updates

- Стратегия обучается путём **максимизации Q-функции** (как в DDPG):

$$\max_{\theta} \mathbb{E}_{s \sim \mathcal{D}} [Q_{\phi_1}(s, \mu_{\theta}(s))]$$

- Ключевое отличие: стратегия обновляется **реже** Q-функций
- Это **снижает нестабильность обучения**, вызванную быстрыми изменениями целей

Псевдокод TD3

Вход: параметры стратегии θ , Q-функций ϕ_1, ϕ_2 , пустой буфер $\mathcal{D}$

1: $\theta_{\text{targ}} \leftarrow \theta, \phi_{\text{targ},i} \leftarrow \phi_i$ для $i = 1, 2$
2: **repeat**

17: **until** СХОДИМОСТЬ

Псевдокод TD3

Вход: параметры стратегии θ , Q-функций ϕ_1, ϕ_2 , пустой буфер $\mathcal{D}$

- 1: $\theta_{\text{targ}} \leftarrow \theta, \phi_{\text{targ},i} \leftarrow \phi_i$ для $i = 1, 2$
- 2: **repeat**
- 3: Получаем s , выбираем $a = \text{clip}(\mu_{\theta}(s) + \epsilon, a_{\text{low}}, a_{\text{high}}), \epsilon \sim \mathcal{N}$
- 4: Выполняем a , получаем s', r, d ; сохраняем (s, a, r, s', d) в $\mathcal{D}$

17: **until** СХОДИМОСТЬ

Псевдокод TD3

Вход: параметры стратегии θ , Q-функций ϕ_1, ϕ_2 , пустой буфер $\mathcal{D}$

```
1:  $\theta_{\text{targ}} \leftarrow \theta, \phi_{\text{targ},i} \leftarrow \phi_i$  для  $i = 1, 2$ 
2: repeat
3:   Получаем  $s$ , выбираем  $a = \text{clip}(\mu_\theta(s) + \epsilon, a_{\text{low}}, a_{\text{high}}), \epsilon \sim \mathcal{N}$ 
4:   Выполняем  $a$ , получаем  $s', r, d$ ; сохраняем  $(s, a, r, s', d)$  в  $\mathcal{D}$ 
5:   if пора обновлять then
6:     for  $j = 1, 2, \dots$  do
7:       Батч  $B = \{(s, a, r, s', d)\}$  из  $\mathcal{D}$ 

15:     end for
16:   end if
17: until СХОДИМОСТЬ
```

Псевдокод TD3

Вход: параметры стратегии θ , Q-функций ϕ_1, ϕ_2 , пустой буфер $\mathcal{D}$

```
1:  $\theta_{\text{targ}} \leftarrow \theta, \phi_{\text{targ},i} \leftarrow \phi_i$  для  $i = 1, 2$ 
2: repeat
3:   Получаем  $s$ , выбираем  $a = \text{clip}(\mu_{\theta}(s) + \epsilon, a_{\text{low}}, a_{\text{high}}), \epsilon \sim \mathcal{N}$ 
4:   Выполняем  $a$ , получаем  $s', r, d$ ; сохраняем  $(s, a, r, s', d)$  в  $\mathcal{D}$ 
5:   if пора обновлять then
6:     for  $j = 1, 2, \dots$  do
7:       Батч  $B = \{(s, a, r, s', d)\}$  из  $\mathcal{D}$ 
8:        $a'(s') = \text{clip}(\mu_{\theta_{\text{targ}}}(s') + \text{clip}(\tilde{\epsilon}, -c, c), a_{\text{low}}, a_{\text{high}})$  ▷ сглаживание
9:        $y = r + \gamma(1 - d) \min_{i=1,2} Q_{\phi_{\text{targ},i}}(s', a'(s'))$  ▷ цели
10:       $\nabla_{\phi_i} \frac{1}{|B|} \sum (Q_{\phi_i}(s, a) - y)^2, i = 1, 2$  ▷ критик
15:     end for
16:   end if
17: until СХОДИМОСТЬ
```

Псевдокод TD3

Вход: параметры стратегии θ , Q-функций ϕ_1, ϕ_2 , пустой буфер $\mathcal{D}$

```
1:  $\theta_{\text{targ}} \leftarrow \theta, \phi_{\text{targ},i} \leftarrow \phi_i$  для  $i = 1, 2$ 
2: repeat
3:   Получаем  $s$ , выбираем  $a = \text{clip}(\mu_\theta(s) + \epsilon, a_{\text{low}}, a_{\text{high}}), \epsilon \sim \mathcal{N}$ 
4:   Выполняем  $a$ , получаем  $s', r, d$ ; сохраняем  $(s, a, r, s', d)$  в  $\mathcal{D}$ 
5:   if пора обновлять then
6:     for  $j = 1, 2, \dots$  do
7:       Батч  $B = \{(s, a, r, s', d)\}$  из  $\mathcal{D}$ 
8:        $a'(s') = \text{clip}(\mu_{\theta_{\text{targ}}}(s') + \text{clip}(\tilde{\epsilon}, -c, c), a_{\text{low}}, a_{\text{high}})$  ▷ сглаживание
9:        $y = r + \gamma(1 - d) \min_{i=1,2} Q_{\phi_{\text{targ},i}}(s', a'(s'))$  ▷ цели
10:       $\nabla_{\phi_i} \frac{1}{|B|} \sum (Q_{\phi_i}(s, a) - y)^2, i = 1, 2$  ▷ критик
11:      if  $j \bmod \text{policy\_delay} = 0$  then ▷ отложенное обновление
12:         $\nabla_{\theta} \frac{1}{|B|} \sum Q_{\phi_1}(s, \mu_\theta(s))$  ▷ актор
14:      end if
15:    end for
16:  end if
17: until СХОДИМОСТЬ
```

Псевдокод TD3

Вход: параметры стратегии θ , Q-функций ϕ_1, ϕ_2 , пустой буфер $\mathcal{D}$

```
1:  $\theta_{\text{targ}} \leftarrow \theta, \phi_{\text{targ},i} \leftarrow \phi_i$  для  $i = 1, 2$ 
2: repeat
3:   Получаем  $s$ , выбираем  $a = \text{clip}(\mu_{\theta}(s) + \epsilon, a_{\text{low}}, a_{\text{high}}), \epsilon \sim \mathcal{N}$ 
4:   Выполняем  $a$ , получаем  $s', r, d$ ; сохраняем  $(s, a, r, s', d)$  в  $\mathcal{D}$ 
5:   if пора обновлять then
6:     for  $j = 1, 2, \dots$  do
7:       Батч  $B = \{(s, a, r, s', d)\}$  из  $\mathcal{D}$ 
8:        $a'(s') = \text{clip}(\mu_{\theta_{\text{targ}}}(s') + \text{clip}(\tilde{\epsilon}, -c, c), a_{\text{low}}, a_{\text{high}})$  ▷ сглаживание
9:        $y = r + \gamma(1 - d) \min_{i=1,2} Q_{\phi_{\text{targ},i}}(s', a'(s'))$  ▷ цели
10:       $\nabla_{\phi_i} \frac{1}{|B|} \sum (Q_{\phi_i}(s, a) - y)^2, i = 1, 2$  ▷ критик
11:      if  $j \bmod \text{policy\_delay} = 0$  then ▷ отложенное обновление
12:         $\nabla_{\theta} \frac{1}{|B|} \sum Q_{\phi_1}(s, \mu_{\theta}(s))$  ▷ актор
13:         $\phi_{\text{targ},i} \leftarrow \rho \phi_{\text{targ},i} + (1 - \rho) \phi_i; \theta_{\text{targ}} \leftarrow \rho \theta_{\text{targ}} + (1 - \rho) \theta$  ▷ Polyak
14:      end if
15:    end for
16:  end if
17: until СХОДИМОСТЬ
```

04

Soft Actor-Critic

Soft Actor-Critic (SAC)

- SAC заполняет разрыв между стохастической оптимизацией градиента стратегии и подходами в стиле DDPG
- Включает метод **clipped double-Q** (как TD3)

Soft Actor-Critic (SAC)

- SAC заполняет разрыв между стохастической оптимизацией градиента стратегии и подходами в стиле DDPG
- Включает метод **clipped double-Q** (как TD3)
- Ключевая особенность — **энтропийная регуляризация**:
 - Стратегия максимизирует **вознаграждение + энтропию**
 - Больше энтропии $\Rightarrow$ больше исследования $\Rightarrow$ быстрее обучение
 - Предотвращает преждевременную сходимость к локальному оптимуму

Энтропия

- Энтропия показывает, насколько **случайна** случайная величина:
 - Смещённая монета (почти всегда орёл) — **низкая энтропия**
 - Сбалансированная монета — **высокая энтропия**

Энтропия

- Энтропия показывает, насколько **случайна** случайная величина:
 - Смещённая монета (почти всегда орёл) — **низкая энтропия**
 - Сбалансированная монета — **высокая энтропия**

Для случайной величины x с распределением P :

$$H(P) = \mathbb{E}_{x \sim P} [-\log P(x)]$$

Энтропия

- Энтропия показывает, насколько **случайна** случайная величина:
 - Смещённая монета (почти всегда орёл) — **низкая энтропия**
 - Сбалансированная монета — **высокая энтропия**

Для случайной величины x с распределением P :

$$H(P) = \mathbb{E}_{x \sim P} [-\log P(x)]$$

Энтропийно-регуляризованная задача RL:

$$\pi^* = \arg \max_{\pi} \mathbb{E}_{\tau \sim \pi} \left[\sum_{t=0}^{\infty} \gamma^t \left(r(s_t, a_t, s_{t+1}) + \alpha H(\pi(\cdot | s_t)) \right) \right]$$

где $\alpha > 0$ — коэффициент температуры

Мягкие функции полезности и уравнение Беллмана

V^π и Q^π включают энтропийные бонусы; их связь:

$$V^\pi(s) = \mathbb{E}_{a \sim \pi} [Q^\pi(s, a) - \alpha \log \pi(a|s)]$$

Мягкие функции полезности и уравнение Беллмана

V^π и Q^π включают энтропийные бонусы; их связь:

$$V^\pi(s) = \mathbb{E}_{a \sim \pi} [Q^\pi(s, a) - \alpha \log \pi(a|s)]$$

Мягкое уравнение Беллмана для Q^π :

$$Q^\pi(s, a) = \mathbb{E}_{s' \sim P, a' \sim \pi} [r(s, a, s') + \gamma (Q^\pi(s', a') - \alpha \log \pi(a'|s'))]$$

Мягкие функции полезности и уравнение Беллмана

V^π и Q^π включают энтропийные бонусы; их связь:

$$V^\pi(s) = \mathbb{E}_{a \sim \pi} [Q^\pi(s, a) - \alpha \log \pi(a|s)]$$

Мягкое уравнение Беллмана для Q^π :

$$Q^\pi(s, a) = \mathbb{E}_{s' \sim P, a' \sim \pi} [r(s, a, s') + \gamma (Q^\pi(s', a') - \alpha \log \pi(a'|s'))]$$

Аппроксимация выборкой:

$$Q^\pi(s, a) \approx r + \gamma (Q^\pi(s', \tilde{a}') - \alpha \log \pi(\tilde{a}'|s')), \quad \tilde{a}' \sim \pi(\cdot|s')$$

Обучение стратегии в SAC

- Стратегия максимизирует

$$V^\pi(s) = \mathbb{E}_{a \sim \pi} [Q^\pi(s, a) - \alpha \log \pi(a|s)]$$

Обучение стратегии в SAC


➤ Стратегия максимизирует

$$V^\pi(s) = \mathbb{E}_{a \sim \pi} [Q^\pi(s, a) - \alpha \log \pi(a|s)]$$

Трюк с репараметризацией: выборка из π_θ через детерминированную функцию:

$$\tilde{a}_\theta(s, \xi) = \tanh(\mu_\theta(s) + \sigma_\theta(s) \odot \xi), \quad \xi \sim \mathcal{N}(0, I)$$

Здесь сеть задаёт $\mu_\theta(s)$ и $\sigma_\theta(s)$ (на практике обычно параметризуют через $\log \sigma_\theta(s)$, $\sigma_\theta(s) = \exp(\log \sigma_\theta(s))$)



Обучение стратегии в SAC

► Стратегия максимизирует

$$V^\pi(s) = \mathbb{E}_{a \sim \pi} [Q^\pi(s, a) - \alpha \log \pi(a|s)]$$


Трюк с репараметризацией: выборка из π_θ через детерминированную функцию:

$$\tilde{a}_\theta(s, \xi) = \tanh(\mu_\theta(s) + \sigma_\theta(s) \odot \xi), \quad \xi \sim \mathcal{N}(0, I)$$

Здесь сеть задаёт $\mu_\theta(s)$ и $\sigma_\theta(s)$ (на практике обычно параметризуют через $\log \sigma_\theta(s)$, $\sigma_\theta(s) = \exp(\log \sigma_\theta(s))$)

Функция потерь стратегии (с min-double-Q):

$$\max_{\theta} \mathbb{E}_{s \sim \mathcal{D}, \xi \sim \mathcal{N}} \left[\min_{j=1,2} Q_{\phi_j}(s, \tilde{a}_\theta(s, \xi)) - \alpha \log \pi_\theta(\tilde{a}_\theta(s, \xi)|s) \right]$$



Ключевые отличия стратегии SAC

1. **Функция сжатия $\tanh$:**

- Гарантирует ограниченный диапазон действий
- Отсутствует в VPG, TRPO, PPO
- Изменяет распределение: до $\tanh$ — гауссова, после — нет

Ключевые отличия стратегии SAC

1. **Функция сжатия $\tanh$:**

- Гарантирует ограниченный диапазон действий
- Отсутствует в VPG, TRPO, PPO
- Изменяет распределение: до $\tanh$ — гауссова, после — нет

2. **Зависящие от состояния σ :**

- В VPG/TRPO/PPO: $\log \sigma$ — фиксированный вектор параметров
- В SAC: $\log \sigma_{\theta}(s)$ — выход нейронной сети (зависит от s)

SAC и TD3: сходства и различия

Сходства с TD3:

- Две Q-функции (MSBE)
- Target сети (Polyak)
- Clipped double-Q

SAC и TD3: сходства и различия

Сходства с TD3:

- Две Q-функции (MSBE)
- Target сети (Polyak)
- Clipped double-Q

Отличия от TD3:

- Цель включает **энтропийный** член
- Действия из **текущей** стратегии (не целевой)
- **Стохастическая** стратегия (нет явного сглаживания)
- Авто-настройка α

SAC и TD3: сходства и различия

Сходства с TD3:

- Две Q-функции (MSBE)
- Target сети (Polyak)
- Clipped double-Q

Отличия от TD3:

- Цель включает **энтропийный** член
- Действия из **текущей** стратегии (не целевой)
- **Стохастическая** стратегия (нет явного сглаживания)
- Авто-настройка α

Функция потерь в SAC:

$$L(\phi_i, \mathcal{D}) = \mathbb{E}_{(s,a,r,s',d) \sim \mathcal{D}} \left[(Q_{\phi_i}(s, a) - y(r, s', d))^2 \right], \quad y = r + \gamma(1 - d) \left(\min_{j=1,2} Q_{\phi_{\text{targ},j}}(s', \tilde{a}') - \alpha \log \pi_{\theta}(\tilde{a}'|s') \right)$$

Что регулирует α ?

Актор учится максимизировать

$$\mathbb{E}[Q(s, a)] + \alpha H(\pi(\cdot|s)).$$

α задаёт, насколько важна энтропия при выборе стратегии.

Что регулирует α ?

Актор учится максимизировать

$$\mathbb{E}[Q(s, a)] + \alpha H(\pi(\cdot|s)).$$

α задаёт, насколько важна энтропия при выборе стратегии.

Малое α

Актор сильнее сосредоточен на действиях с высоким Q .

Большое α

Актору выгоднее сохранять разнообразие действий.

Что регулирует α ?

Актор учится максимизировать

$$\mathbb{E}[Q(s, a)] + \alpha H(\pi(\cdot|s)).$$

α задаёт, насколько важна энтропия при выборе стратегии.

Малое α

Актор сильнее сосредоточен на действиях с высоким Q .

Большое α

Актору выгоднее сохранять разнообразие действий.

Почему сложно выбрать одно значение?

Масштаб Q зависит от вознаграждений и меняется при обучении. Один и тот же вес энтропии может оказаться слишком слабым или слишком сильным.

Настраиваем α по текущей энтропии

Идея: задаём целевую энтропию $\mathcal{H}_{\text{target}}$ и подстраиваем под неё вес α .

Настраиваем α по текущей энтропии

Идея: задаём целевую энтропию $\mathcal{H}_{\text{target}}$ и подстраиваем под неё вес α .

Энтропия ниже целевой

$$\mathcal{H}_{\text{cur}} < \mathcal{H}_{\text{target}} \quad \Rightarrow \quad \alpha \uparrow$$

Усиливаем бонус за энтропию: актору выгоднее разнообразить действия.

Настраиваем α по текущей энтропии

Идея: задаём целевую энтропию $\mathcal{H}_{\text{target}}$ и подстраиваем под неё вес α .

Энтропия ниже целевой

$$\mathcal{H}_{\text{cur}} < \mathcal{H}_{\text{target}} \implies \alpha \uparrow$$

Усиливаем бонус за энтропию: актору выгоднее разнообразить действия.

Энтропия выше целевой

$$\mathcal{H}_{\text{cur}} > \mathcal{H}_{\text{target}} \implies \alpha \downarrow$$

Ослабляем бонус: актор может сильнее сосредоточиться на высоком Q .

Настраиваем α по текущей энтропии

Идея: задаём целевую энтропию $\mathcal{H}_{\text{target}}$ и подстраиваем под неё вес α .

Энтропия ниже целевой

$$\mathcal{H}_{\text{cur}} < \mathcal{H}_{\text{target}} \implies \alpha \uparrow$$

Усиливаем бонус за энтропию: актору выгоднее разнообразить действия.

Энтропия выше целевой

$$\mathcal{H}_{\text{cur}} > \mathcal{H}_{\text{target}} \implies \alpha \downarrow$$

Ослабляем бонус: актор может сильнее сосредоточиться на высоком Q .

Сравниваем **среднюю энтропию по батчу состояний**. В разных состояниях стратегия может иметь разную энтропию.

Обновление α : один шаг по ошибке энтропии

1. Оцениваем энтропию текущей стратегии.

Берём состояния s_i из replay buffer и новые действия $a_i \sim \pi_\theta(\cdot|s_i)$:

$$\hat{\mathcal{H}}_{\text{cur}} = -\frac{1}{B} \sum_{i=1}^B \log \pi_\theta(a_i|s_i).$$

Обновление α : один шаг по ошибке энтропии

1. Оцениваем энтропию текущей стратегии.

Берём состояния s_i из replay buffer и новые действия $a_i \sim \pi_\theta(\cdot|s_i)$:

$$\hat{\mathcal{H}}_{\text{cur}} = -\frac{1}{B} \sum_{i=1}^B \log \pi_\theta(a_i|s_i).$$

2. Минимизируем простую функцию потерь по α .

$$L_\alpha = \alpha(\hat{\mathcal{H}}_{\text{cur}} - \mathcal{H}_{\text{target}}), \quad \frac{\partial L_\alpha}{\partial \alpha} = \hat{\mathcal{H}}_{\text{cur}} - \mathcal{H}_{\text{target}}.$$

Ошибка отрицательна — градиентный спуск увеличивает α ; положительна — уменьшает.

Обновление α : один шаг по ошибке энтропии

1. Оцениваем энтропию текущей стратегии.

Берём состояния s_i из replay buffer и новые действия $a_i \sim \pi_\theta(\cdot|s_i)$:

$$\hat{\mathcal{H}}_{\text{cur}} = -\frac{1}{B} \sum_{i=1}^B \log \pi_\theta(a_i|s_i).$$

2. Минимизируем простую функцию потерь по α .

$$L_\alpha = \alpha(\hat{\mathcal{H}}_{\text{cur}} - \mathcal{H}_{\text{target}}), \quad \frac{\partial L_\alpha}{\partial \alpha} = \hat{\mathcal{H}}_{\text{cur}} - \mathcal{H}_{\text{target}}.$$

Ошибка отрицательна — градиентный спуск увеличивает α ; положительна — уменьшает.

При этом шаге: стратегию и оценку энтропии фиксируем. Для $\alpha > 0$ на практике оптимизируют $\log \alpha$.

Псевдокод SAC

Вход: параметры стратегии θ , Q-функций ϕ_1, ϕ_2 , пустой буфер $\mathcal{D}$

1: $\phi_{\text{targ},i} \leftarrow \phi_i$ для $i = 1, 2$

2: **repeat**

16: **until** СХОДИМОСТЬ

Псевдокод SAC

Вход: параметры стратегии θ , Q-функций ϕ_1, ϕ_2 , пустой буфер $\mathcal{D}$

- 1: $\phi_{\text{targ},i} \leftarrow \phi_i$ для $i = 1, 2$
- 2: **repeat**
- 3: Получаем s , выбираем $a \sim \pi_\theta(\cdot|s)$, выполняем a
- 4: Получаем s', r, d ; сохраняем (s, a, r, s', d) в $\mathcal{D}$

16: **until** СХОДИМОСТЬ

Псевдокод SAC

Вход: параметры стратегии θ , Q-функций ϕ_1, ϕ_2 , пустой буфер $\mathcal{D}$

```
1:  $\phi_{\text{targ},i} \leftarrow \phi_i$  для  $i = 1, 2$ 
2: repeat
3:   Получаем  $s$ , выбираем  $a \sim \pi_\theta(\cdot|s)$ , выполняем  $a$ 
4:   Получаем  $s', r, d$ ; сохраняем  $(s, a, r, s', d)$  в  $\mathcal{D}$ 
5:   if пора обновлять then
6:     for  $j = 1, 2, \dots$  do
7:       Батч  $B = \{(s, a, r, s', d)\}$  из  $\mathcal{D}$ 
```

```
14:   end for
15: end if
16: until СХОДИМОСТЬ
```

Псевдокод SAC

Вход: параметры стратегии θ , Q-функций ϕ_1, ϕ_2 , пустой буфер $\mathcal{D}$

```
1:  $\phi_{\text{targ},i} \leftarrow \phi_i$  для  $i = 1, 2$ 
2: repeat
3:   Получаем  $s$ , выбираем  $a \sim \pi_\theta(\cdot|s)$ , выполняем  $a$ 
4:   Получаем  $s', r, d$ ; сохраняем  $(s, a, r, s', d)$  в  $\mathcal{D}$ 
5:   if пора обновлять then
6:     for  $j = 1, 2, \dots$  do
7:       Батч  $B = \{(s, a, r, s', d)\}$  из  $\mathcal{D}$ 
8:        $\tilde{a}' \sim \pi_\theta(\cdot|s')$  ▷ сэмпл из текущей стратегии
9:        $y = r + \gamma(1 - d)(\min_{i=1,2} Q_{\phi_{\text{targ},i}}(s', \tilde{a}') - \alpha \log \pi_\theta(\tilde{a}'|s'))$  ▷ цели
10:       $\nabla_{\phi_i} \frac{1}{|B|} \sum (Q_{\phi_i}(s, a) - y)^2, i = 1, 2$  ▷ критик
14:     end for
15:   end if
16: until сходимось
```

Псевдокод SAC

Вход: параметры стратегии θ , Q-функций ϕ_1, ϕ_2 , пустой буфер $\mathcal{D}$

```
1:  $\phi_{\text{targ},i} \leftarrow \phi_i$  для  $i = 1, 2$ 
2: repeat
3:   Получаем  $s$ , выбираем  $a \sim \pi_\theta(\cdot|s)$ , выполняем  $a$ 
4:   Получаем  $s', r, d$ ; сохраняем  $(s, a, r, s', d)$  в  $\mathcal{D}$ 
5:   if пора обновлять then
6:     for  $j = 1, 2, \dots$  do
7:       Батч  $B = \{(s, a, r, s', d)\}$  из  $\mathcal{D}$ 
8:        $\tilde{a}' \sim \pi_\theta(\cdot|s')$  ▷ сэмпл из текущей стратегии
9:        $y = r + \gamma(1 - d)(\min_{i=1,2} Q_{\phi_{\text{targ},i}}(s', \tilde{a}') - \alpha \log \pi_\theta(\tilde{a}'|s'))$  ▷ цели
10:       $\nabla_{\phi_i} \frac{1}{|B|} \sum (Q_{\phi_i}(s, a) - y)^2, i = 1, 2$  ▷ критик
11:       $\nabla_{\theta} \frac{1}{|B|} \sum (\min_{i=1,2} Q_{\phi_i}(s, \tilde{a}_\theta) - \alpha \log \pi_\theta(\tilde{a}_\theta|s))$  ▷ актер
14:   end for
15: end if
16: until сходимость
```

Псевдокод SAC

Вход: параметры стратегии θ , Q-функций ϕ_1, ϕ_2 , пустой буфер $\mathcal{D}$

```
1:  $\phi_{\text{targ},i} \leftarrow \phi_i$  для  $i = 1, 2$ 
2: repeat
3:   Получаем  $s$ , выбираем  $a \sim \pi_\theta(\cdot|s)$ , выполняем  $a$ 
4:   Получаем  $s', r, d$ ; сохраняем  $(s, a, r, s', d)$  в  $\mathcal{D}$ 
5:   if пора обновлять then
6:     for  $j = 1, 2, \dots$  do
7:       Батч  $B = \{(s, a, r, s', d)\}$  из  $\mathcal{D}$ 
8:        $\tilde{a}' \sim \pi_\theta(\cdot|s')$  ▷ сэмпл из текущей стратегии
9:        $y = r + \gamma(1 - d)(\min_{i=1,2} Q_{\phi_{\text{targ},i}}(s', \tilde{a}') - \alpha \log \pi_\theta(\tilde{a}'|s'))$  ▷ цели
10:       $\nabla_{\phi_i} \frac{1}{|B|} \sum (Q_{\phi_i}(s, a) - y)^2, i = 1, 2$  ▷ критик
11:       $\nabla_{\theta} \frac{1}{|B|} \sum (\min_{i=1,2} Q_{\phi_i}(s, \tilde{a}_\theta) - \alpha \log \pi_\theta(\tilde{a}_\theta|s))$  ▷ актер
12:       $\alpha \leftarrow \alpha - \lambda_\alpha \nabla_\alpha \frac{1}{|B|} \sum (-\alpha \log \pi_\theta(\tilde{a}|s) - \alpha \mathcal{H}_{\text{target}})$  ▷ авто- $\alpha$ 
14:     end for
15:   end if
16: until сходимость
```

Псевдокод SAC

Вход: параметры стратегии θ , Q-функций ϕ_1, ϕ_2 , пустой буфер $\mathcal{D}$

```
1:  $\phi_{\text{targ},i} \leftarrow \phi_i$  для  $i = 1, 2$ 
2: repeat
3:   Получаем  $s$ , выбираем  $a \sim \pi_\theta(\cdot|s)$ , выполняем  $a$ 
4:   Получаем  $s', r, d$ ; сохраняем  $(s, a, r, s', d)$  в  $\mathcal{D}$ 
5:   if пора обновлять then
6:     for  $j = 1, 2, \dots$  do
7:       Батч  $B = \{(s, a, r, s', d)\}$  из  $\mathcal{D}$ 
8:        $\tilde{a}' \sim \pi_\theta(\cdot|s')$  ▷ сэмпл из текущей стратегии
9:        $y = r + \gamma(1 - d)(\min_{i=1,2} Q_{\phi_{\text{targ},i}}(s', \tilde{a}') - \alpha \log \pi_\theta(\tilde{a}'|s'))$  ▷ цели
10:       $\nabla_{\phi_i} \frac{1}{|B|} \sum (Q_{\phi_i}(s, a) - y)^2, i = 1, 2$  ▷ критик
11:       $\nabla_{\theta} \frac{1}{|B|} \sum (\min_{i=1,2} Q_{\phi_i}(s, \tilde{a}_\theta) - \alpha \log \pi_\theta(\tilde{a}_\theta|s))$  ▷ актер
12:       $\alpha \leftarrow \alpha - \lambda_\alpha \nabla_{\alpha} \frac{1}{|B|} \sum (-\alpha \log \pi_\theta(\tilde{a}|s) - \alpha \mathcal{H}_{\text{target}})$  ▷ авто- $\alpha$ 
13:       $\phi_{\text{targ},i} \leftarrow \rho \phi_{\text{targ},i} + (1 - \rho) \phi_i, i = 1, 2$  ▷ Polyak
14:     end for
15:   end if
16: until сходимось
```

Сравнение: DDPG vs TD3 vs SAC

	DDPG	TD3	SAC
Стратегия	детерм.	детерм.	стохаст.
Исследование	внешний шум	внешний шум	энтропия
Q-сети	1	2	2
Целевая сеть актора	да	да	нет
Отлож. обновления	нет	да	нет
Ключевая идея	DPG + replay	3 стабилизации	max-ent RL

Сравнение: DDPG vs TD3 vs SAC

	DDPG	TD3	SAC
Стратегия	детерм.	детерм.	стохаст.
Исследование	внешний шум	внешний шум	энтропия
Q-сети	1	2	2
Целевая сеть актора	да	да	нет
Отлож. обновления	нет	да	нет
Ключевая идея	DPG + replay	3 стабилизации	max-ent RL

Рекомендации:

- **SAC** — рекомендация по умолчанию (робастность, исследование)
- **TD3** — сильная альтернатива
- **DDPG** — только как baseline

Практические рекомендации

Типичные гиперпараметры (SAC / TD3):

- Learning rate: 3×10^{-4} (Adam), batch size: 256
- Replay buffer: 10^6 переходов, Polyak $\rho = 0.995$
- Начало обучения: после 10^4 случайных шагов (заполнение буфера)

Практические рекомендации

Типичные гиперпараметры (SAC / TD3):

- Learning rate: 3×10^{-4} (Adam), batch size: 256
- Replay buffer: 10^6 переходов, Polyak $\rho = 0.995$
- Начало обучения: после 10^4 случайных шагов (заполнение буфера)

Частые ошибки:

- Отсутствие **нормализации наблюдений** (running mean/std)
- Неправильное **масштабирование наград** (слишком большие $\Rightarrow$ взрыв Q)
- Игнорирование **границ действий** (clip / tanh)
- Слишком маленький буфер или слишком ранний старт обучения

Вопросы?

SAC для дискретных действий

Вопрос: как адаптировать SAC для **дискретного** пространства действий?

Подсказки:

1. Что заменяет гауссово распределение?
2. Нужен ли трюк с репараметризацией, если можно перебрать все действия?
3. Как изменится функция потерь актора?
4. Как точно вычислить энтропию $H(\pi(\cdot|s))$?

Вход: θ, ϕ_1, ϕ_2 , буфер $\mathcal{D}$

```
1:  $\phi_{\text{targ},i} \leftarrow \phi_i$  для  $i = 1, 2$ 
2: repeat
3:   Получаем  $s$ , выбираем  $a \sim \pi_\theta(\cdot|s)$ , выполняем  $a$ 
4:   Получаем  $s', r, d$ ; сохраняем  $(s, a, r, s', d)$  в  $\mathcal{D}$ 
5:   if пора обновлять then
6:     for  $j = 1, 2, \dots$  do
7:       Батч  $B$  из  $\mathcal{D}$ 
8:        $\tilde{a}' \sim \pi_\theta(\cdot|s')$  ▷ сэмпл
9:        $y = r + \gamma(1 - d)(\min_i Q_{\phi_{\text{targ},i}}(s', \tilde{a}') - \alpha \log \pi_\theta(\tilde{a}'|s'))$ 
10:       $\nabla_{\phi_i} \frac{1}{|B|} \sum (Q_{\phi_i}(s, a) - y)^2$  ▷ критик
11:       $\nabla_\theta \frac{1}{|B|} \sum (\min_i Q_{\phi_i}(s, \tilde{a}_\theta) - \alpha \log \pi_\theta(\tilde{a}_\theta|s))$  ▷ актер
12:      Обновляем  $\alpha$  ▷ авто- $\alpha$ 
13:      Polyak:  $\phi_{\text{targ},i} \leftarrow \rho \phi_{\text{targ},i} + (1 - \rho) \phi_i$ 
14:    end for
15:  end if
16: until сходимость
```